



# Dev - Probabilidade I

## Síntese

- Limites de Conjuntos
- Leis de De Morgan
- Propriedades distributiva
- Arranjos
- Arranjos com repetição
- Permutações
- Permutações Circular
- Permutações Com Repetição
- Combinações
- Teorema Conjuntos
- Probabilidade condicional
- Teorema da multiplicação
- Independência de dois eventos
- Variáveis Aleatórias (v.a)
  - Definição
  - Variáveis Aleatórias Discreta
  - Variáveis Aleatórias Continua
- Distribuição de Probabilidade
  - Função Discreta de Probabilidade
  - Definição de Distribuição de Probabilidade
- Função de Distribuição Acumulada (f.d.a)
  - Definição
  - De Distribuição de Probabilidade para f.d.a
- Esperança de v.a. Discretas ( $\mathbb{E}(X)$ )
  - Definição
  - Propriedades
- Variância de uma v.a. ( $Var(X)$ )
  - Definição
  - Propriedades
- Resumo das distribuições discretas
- Distribuição Uniforme Discreta
  - Definição
- Modelo Bernoulli
  - Definição
- Distribuição Bernoulli
  - Definição
- Distribuição Binomial

- Definição
- Distribuição Hipergeométrica
  - Definição
- Distribuição Geométrica
  - Definição
- Distribuição Binomial Negativa (Pascal)
  - Definição
- Distribuição Poisson
  - Definição
- Função Geradora de Probabilidade
  - Definição
  - Binomial
  - Geométrica
  - Poisson
- Função Geradora de Momento
  - Definição
  - Função Característica
  - Binomial
  - Geométrica
  - Poisson

## Limites de Conjuntos



- A definição de conceitos de convergência para variáveis aleatórias baseia-se em manipulações de sequências de eventos que requerem limites de conjuntos. Seja  $A_n \subset \Omega$  definimos

$$\inf_{k \geq n} A_k := \bigcap_{k=n}^{\infty} A_k, \quad \sup_{k \geq n} A_k := \bigcup_{k=n}^{\infty} A_k$$

$$\liminf_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k,$$

$$\limsup_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k.$$

- O limite de uma sequência de conjuntos é definido da seguinte forma: Se para alguma sequência  $\{B_n\}$  de subconjuntos

$$\limsup_{n \rightarrow \infty} B_n = \liminf_{n \rightarrow \infty} B_n = B,$$

então  $B$  é chamado de limite de  $B_n$  e escrevemos  $\lim_{n \rightarrow \infty} B_n = B$  ou  $B_n \rightarrow B$  será demonstrado em breve que

$$\liminf_{n \rightarrow \infty} A_n = \lim_{n \rightarrow \infty} \left( \inf_{k \geq n} A_k \right)$$

and

$$\limsup_{n \rightarrow \infty} A_n = \lim_{n \rightarrow \infty} \left( \sup_{k \geq n} A_k \right).$$

- **Exemplo:**

$$\liminf_{n \rightarrow \infty} [0, n/(n+1)) = \limsup_{n \rightarrow \infty} [0, n/(n+1)) = [0, 1). \quad \square$$

Podemos agora dar uma interpretação de  $\liminf_{n \rightarrow \infty} A_n$  e  $\limsup_{n \rightarrow \infty} A_n$ .

**LEMA:** Seja  $\{A_n\}$  uma sequência de subconjuntos de  $\Omega$ .

a. Para  $\limsup$  temos a interpretação

$$\begin{aligned} \limsup_{n \rightarrow \infty} A_n &= \left\{ \omega : \sum_{n=1}^{\infty} 1_{A_n}(\omega) = \infty \right\} \\ &= \left\{ \omega : \omega \in A_{n_k}, k = 1, 2, \dots \right\} \end{aligned}$$

para alguma subsequência  $n_k$  dependendo de  $\omega$ . Consequentemente, escrevemos

$$\limsup_{n \rightarrow \infty} A_n = [A_n \text{ i.o. }]$$

onde *i.o.* significa infinitamente frequentemente.

b. Para  $\liminf$  temos a interpretação

$$\begin{aligned} \liminf_{n \rightarrow \infty} A_n &= \{ \omega : \omega \in A_n \text{ for all } n \text{ except a finite number} \} \\ &= \{ \omega : \sum_n 1_{A_n^c}(\omega) < \infty \} \\ &= \{ \omega : \omega \in A_n, \forall n \geq n_0(\omega) \}. \end{aligned}$$

**Prova (a):** Se

$$\omega \in \limsup_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k,$$

então para todo  $n$ ,  $\omega \in \bigcup_{k \geq n} A_k$  e assim para todo  $n$ , existe algum  $k_n \geq n$  tal que  $\omega \in A_{k_n}$ , e portanto

$$\sum_{j=1}^{\infty} 1_{A_j}(\omega) \geq \sum_n 1_{A_{k_n}}(\omega) = \infty,$$

que implica

$$\omega \in \left\{ \omega : \sum_{n=1}^{\infty} 1_{A_n}(\omega) = \infty \right\};$$

portanto

$$\limsup_{n \rightarrow \infty} A_n \subset \left\{ \omega : \sum_{j=1}^{\infty} 1_{A_j}(\omega) = \infty \right\}.$$

Inversamente, se

$$\omega \in \left\{ \omega : \sum_{j=1}^{\infty} 1_{A_j}(\omega) = \infty \right\},$$

então existe  $k_n \rightarrow \infty$  tal que  $\omega \in A_{k_n}$ , e portanto para todo  $n$ ,  $\omega \in \bigcup_{j \geq n} A_j$  tal que  $\omega \in \limsup_{n \rightarrow \infty} A_n$ . Por definição

$$\{\omega : \sum_{j=1}^{\infty} 1_{A_j}(\omega) = \infty\} \subset \limsup_{n \rightarrow \infty} A_n.$$

Isso prova a inclusão do conjunto em ambas as direções e mostra a igualdade.

**Prova (b):** A prova de (b) é análoga.

## Leis de De Morgan

- $(A \cup B)^c = A^c \cap B^c$
- $(A \cap B)^c = A^c \cup B^c$

## Propriedades distributiva

- $(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$
- $(A \cap B) \cup C = (A \cup C) \cap (B \cup C)$

## Arranjos

$$A_{m,r} = \frac{m!}{(m-r)!}$$

- Seja  $M$  um conjunto com  $m$  elementos, isto é,  $M = \{a_1, a_2, \dots, a_m\}$ . Chamamos de arranjo dos  $m$  elementos tomados  $r$  a  $r$  ( $1 \leq r \leq m$ ) a qualquer  $r$ -upla (sequência de  $r$  elementos) formada com elementos de  $M$ , todos distintos.

## Arranjos com repetição

$$(AR)_{m,r} = \underbrace{m \cdot m \cdot \dots \cdot m}_{r \text{ vezes}} = m^r$$

- Seja  $M$  um conjunto com  $m$  elementos, isto é,  $M = \{a_1, a_2, \dots, a_m\}$ . Chamamos arranjo com repetição dos  $m$  elementos, tomados  $r$  a  $r$ , toda  $r$ -upla ordenada (sequência de tamanho  $r$ ) formada com elementos de  $M$  não necessariamente distintos.

## Permutações


$$P_m = m \cdot (m-1) \cdot (m-2) \cdot \dots \cdot 3 \cdot 2 \cdot 1$$

- Seja  $M$  um conjunto com  $m$  elementos, isto é,  $M = \{a_1, a_2, \dots, a_m\}$ . Chamamos de permutação dos  $m$  elementos a todo arranjo em que  $r = m$ .


## Permutações Circular

- Quando elementos são dispostos ao redor de um círculo, a cada disposição possível chamamos permutação circular.
- Duas permutações circulares são consideradas idênticas, quando:

1) Tomando o elemento A, a sequência encontrada é (A,C, D, B).



2) Tomando o elemento A, a sequência encontrada é (A, C, D, B).



•

$$x = \frac{n!}{n} = (n - 1)!$$

## Permutações Com Repetição

$$P_n^{n_1, n_2, \dots, n_r} = \frac{n!}{n_1! n_2! \dots n_r!}$$

## Combinações

$$C_{m,r} = \binom{m}{r} = \frac{m!}{r! (m-r)!} \quad \forall m, r \in \mathbb{N}^*, r < m$$

• Casos particulares:

1º caso:  $m, r \in \mathbb{N}^*$  e  $r = m$

$$\begin{cases} C_{m,m} = 1 \\ \frac{m!}{m!(m-m)!} = 1 \end{cases}$$

2º caso:  $m \in \mathbb{N}^*$  e  $r = 0$

$$\begin{cases} C_{m,0} = 1 \text{ (o único subconjunto com 0 elemento é o vazio)} \\ \frac{m!}{0! (m-0)!} = 1 \end{cases}$$

3º caso:  $m = 0$  e  $r = 0$

$$\begin{cases} C_{0,0} = 1 \text{ (o único subconjunto do conjunto vazio é o próprio vazio)} \\ \frac{0!}{0! (0-0)!} = 1 \end{cases}$$

## Teorema Conjuntos


- Se  $A \subset B$ , então  $P(A) \leq P(B)$ .
- Se  $A$  é um evento, então  $0 \leq P(A) \leq 1$ .
- $P(A) = 1 - P(A^c)$
- Sendo  $A$  e  $B$  dois eventos quaisquer, vale  $P(B) = P(B \cap A) + P(B \cap A^c)$ .
- Regra da Adição de Probabilidades. Se  $A$  e  $B$  são eventos, então  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- Para eventos quaisquer  $A_1, A_2, \dots$

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) \leq \sum_{i=1}^{\infty} P(A_i)$$

- Se os eventos  $A_1, A_2, \dots$  são mutuamente exclusivos, então:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

- Se  $A$  e  $B$  são mutuamente exclusivos ( $A \cap B = \emptyset$ ), então  $P(A \cup B) = P(A) + P(B) - P(\emptyset) = P(A) + P(B)$ .



- Se  $A$  é um evento, então  $P(A^c) = 1 - P(A)$
- **Continuidade da Probabilidade:** Se  $A_n \uparrow A$  então  $P(A_n) \uparrow P(A)$ . De forma similar, se  $A_n \downarrow A$  então  $P(A_n) \downarrow P(A)$ . A notação  $A_n \uparrow A$  indica que temos uma sequência monótona não decrescente ( $n \leq n+1$ ) de eventos  $A_1, A_2, \dots$  tais que  $\lim_{i \rightarrow \infty} A_i = A = \bigcup_{i=1}^{\infty} A_i$ .

## Probabilidade condicional

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad P(B) > 0$$

## Teorema da multiplicação

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \Rightarrow P(A \cap B) = P(B) \cdot P(A|B)$$

$$P(B|A) = \frac{P(A \cap B)}{P(A)} \Rightarrow P(A \cap B) = P(A) \cdot P(B|A)$$

## Independência de dois eventos

- Dois eventos  $A$  e  $B$  de um espaço amostral  $\Omega$ , são chamados **independentes** se  $P(A \cap B) = P(A) \cdot P(B)$ . Ou seja, se os eventos são independentes a ocorrência de um não altera a probabilidade de ocorrência do outro.

$$P(B|A) = \frac{P(A \cap B)}{P(A)} = \frac{P(B) \cdot P(A|B)}{P(A)} = \frac{P(B) \cdot P(A)}{P(A)} = P(B)$$

Dois eventos  $A$  e  $B$  são independentes se, e somente se a definição é verdadeira:

$$P(A \cap B) = P(A)P(B)$$

- Obs:** Sejam  $A$  e  $B$  eventos de um espaço amostral  $\Omega$  tais que  $P(A) > 0$  e  $P(B) > 0$ . Se  $A$  e  $B$  são **INDEPENDENTES**, então  $A$  e  $B$  não podem ser **MUTUAMENTE EXCLUDENTES**.

## Variáveis Aleatórias (v.a)

### ▼ Definição

- A variável aleatória vai associar um valor real para cada valor do espaço amostral  $\Omega$ .

**Ex:** Lançar duas moedas consecutivamente

- Notação  $C = cara$ ,  $K = coroa$ .
- $\Omega = \{\omega_1, \omega_2, \omega_3, \omega_4\}$
- $\omega_1 = (C, C)$ ;  $\omega_2 = (C, K)$ ;  $\omega_3 = (K, C)$ ;  $\omega_4 = (K, K)$
- Defina  $X$ : O número de coroas observadas.

$$\begin{aligned}\omega_1 \rightarrow X &= 0 \\ \omega_2 \text{ ou } \omega_3 \rightarrow X &= 1 \\ \omega_4 \rightarrow X &= 2\end{aligned}$$


- De uma maneira mais formal: Uma variável aleatória é uma função definida num espaço amostral, que assume valores reais.
- Em outras palavras. Uma variável aleatória  $X$  representa um valor real, associado a cada resultado de um experimento de probabilidade. Ou seja para cada valor do  $\Omega$  vai existir um valor  $x$  dentro da variável aleatória  $X$ .
- Obs:** As variáveis aleatórias são representadas por letras maiúsculas  $X$ . E os valores assumidos pelas variáveis aleatórias são representados por letras minúsculas ( $x$ ).

## Definição

Sejam  $\varepsilon$  um experimento aleatório e  $\Omega$  o espaço amostral associado a este. Uma *função*  $X$ , que associe a cada elemento  $\omega \in \Omega$  um número real,  $X(\omega)$ , é denominada variável aleatória (v.a).

## Notação:

- Letras maiúsculas (variável aleatória),  $X, Y, Z$ , etc.
- Letras minúsculas, (valor assumido pela variável aleatória),  $x, y, z$  etc.



## Exemplos:

- (a) Número de peças defeituosas entre  $n$  peças retiradas de uma linha de produção.  
 $X = \{x | x \in \{0, 1, 2, \dots, D\}\}$  onde  $D$  é o total de peças defeituosas
- (b) Número de veículos que passam por um posto de pedágio durante uma hora.  
 $X = \{x | x \in \{0, 1, 2, \dots\}\}$
- (c) Sexo de um indivíduo selecionado ao acaso de uma população  
 $X = \{x | x = 0 \text{ ou } x = 1\}$
- (d) Tempo de duração de um componente de um circuito.  
 $X = \{x | x \in [0, \infty)\}$
- (e) Peso de animais sujeitos a uma dieta de engorda.  
 $X = \{x | x \in [0, \infty)\}$

- **Definição:** As variáveis aleatórias que assumem valores em um conjunto enumerável serão denominadas **Discretas** e aquelas que assumem valores em um intervalo da reta real serão denominadas **Contínuas**.

### ▼ Variáveis Aleatórias Discreta

- Uma variável aleatória é discreta se ela assume um **número finito** de valores ou assume um **número infinito de valores numeráveis** (contáveis).
- Ou seja, podemos dizer que uma variável é discreta quando seus valores puderem ser listados.



**Por exemplo:** o número de ligações recebidas por dia em um escritório pode ser um valor igual a 0, 1, 2, 3, 4, ... Assim, definimos a variável aleatória X:

X: número de ligações recebidas pelo escritório.

Os valores que essa variável pode assumir são  $x=0, 1, 2, 3, \dots$ . Dessa forma, se escrevermos  $X=3$  estamos dizendo que “o número de ligações recebidas pelo escritório (X) é igual a 3 ligações (x)”.

#### ▼ Variáveis Aleatórias Contínuas

- Uma variável aleatória é contínua se ela possui um **número incontável** de possíveis resultados.
- Ou seja, uma variável é dita contínua quando os valores que ela pode assumir puderem ser representados como um **intervalo na reta dos números reais**.
- Neste caso, os valores assumidos por uma variável contínua **não podem ser listados**, visto que **são infinitos** os possíveis valores dessa variável.

**Por exemplo:** consideremos o tempo de duração de uma ligação recebida em minutos (incluindo frações de minutos). Neste caso, podemos definir uma variável aleatória Y da seguinte forma:

Y: tempo de duração de uma ligação em minutos.

Perceba que os valores de Y podem assumir qualquer valor em um intervalo real. Suponhamos, para facilitar, que o tempo máximo de uma ligação seja de 120 minutos. Neste caso, os valores y pertencem ao intervalo  $[0, 120]$ .

## Distribuição de Probabilidade

#### ▼ Função Discreta de Probabilidade

- Para cada valor  $x_1, x_2, x_3, \dots$  de uma variável aleatória discreta (X) pode-se determinar uma probabilidade correspondente a esse valor. Ou seja, para cada  $x_i$  vai ser atribuído uma probabilidade de ocorrer.
- Representamos essa probabilidade da seguinte maneira:  $P(x_i)$  que é a mesma coisa que  $\mathbb{P}(X = x_i)$ . Essas duas expressões são chamadas de **Função de Probabilidade** ou **Funções Discretas de Probabilidade**.

$$P(x_i) = \mathbb{P}(X = x_i)$$

#### ▼ Definição de Distribuição de Probabilidade

- A **Distribuição de probabilidade** vai ser a coleção de todas as probabilidades que foram atribuídas aos  $x_i$ .
- Uma distribuição de probabilidades deve satisfazer a duas condições:
  - i. A probabilidade de cada valor  $p(x_i)$  da variável aleatória tem que ser um número de 0 á 1.

$$0 \leq \mathbb{P}(X = x) \leq 1 \quad \text{ou} \quad 0 \leq P(x) \leq 1$$

- ii. A soma de todas as probabilidades tem que ser igual a 1.

$$\sum_i \mathbb{P}(X = x_i) = 1 \quad \text{ou} \quad \sum_i p(x_i) = 1$$

## Definição

Seja  $X$  uma variável aleatória discreta. Portanto,  $X$  assume no máximo um número infinito enumerável de valores  $x_1, x_2, \dots$ . A cada possível resultado  $x_i$  associaremos um número  $p(x_i) = \mathbb{P}(X = x_i)$ , denominado probabilidade de  $x_i$  satisfazendo as seguintes condições:


- (a)  $p(x_i) \geq 0$  para todo  $i$ ,
- (b)  $\sum_i p(x_i) = 1$ .

A função  $p(x_i)$  é chamada *função de probabilidade* e a coleção de pares  $[x_i, p(x_i)]$ ,  $i = 1, 2, \dots$ , é denominada *distribuição de probabilidade* de  $X$ .


### ▼ Exemplos

#### ▼ Ex 1

- Considere uma urna com duas bolas brancas e três bolas vermelhas. Dessa urna, são extraídas, sem reposição, duas bolas. Seja  $X$ : “número de bolas vermelhas obtidas nas duas extrações”. Determine a distribuição de probabilidade de  $X$ .



- Os casos possíveis de retirar duas bolas da urna sem reposição são:  $\Omega = (B, B), (B, V), (V, B), (V, V)$ .



- Seja  $X$ : “número de bolas vermelhas obtidas nas duas extrações”. Logo os valores que a variável aleatória ( $X$ ) pode assumir são  $x = \{0, 1, 2\}$ .
- Então a probabilidade de cada  $x$  vai ser:

$$P(x) = P(X = x) \quad \forall x \in \{0, 1, 2\}$$

$$P(0) = P(X = 0) = \frac{1}{\binom{5}{2}} = \frac{1}{10}$$

$$P(1) = P(X = 1) = \frac{\binom{3}{1}\binom{2}{1}}{\binom{5}{2}} = \frac{6}{10}$$

$$P(2) = P(X = 2) = \frac{\binom{3}{2}}{\binom{5}{2}} = \frac{3}{10}$$

- Só para termos certeza que é realmente uma distribuição de probabilidade, vamos ver se ela satisfaz as duas condições de distribuição de probabilidade.

1. Nitidamente percebemos que os valores são  $0 \leq x_i \leq 1$ .
2. Vamos somar todos os valores para ver se resulta em 1.

$$\sum_{x=0}^2 P(x) = \frac{1}{10} + \frac{6}{10} + \frac{3}{10} = 1$$

- Logo a distribuição de probabilidade vai ser

x	0	1	2
P(x)	1/10	6/10	3/10

### ▼ Ex 2

- Número de filhos - Com dados do último censo, a assistente social de um centro de saúde constatou que para as famílias de uma determinada região:
  - 20% não têm filhos
  - 30% têm 1 filho
  - 35% têm 2 filhos
  - 15% têm igualmente 3, 4 ou 5 filhos
- Vamos definir a variável aleatória  $N =$  “número de filhos por família”.
- Suponha que uma família será selecionada aleatoriamente nessa região e o número de filhos averiguado, queremos estudar a v.a  $N$ .

## Função de Distribuição Acumulada (f.d.a)

- O conceito de Função de Distribuição Acumulada (ou **Distribuição Cumulativa de Probabilidade** ou **Função de Distribuição**) que introduziremos aplica-se tanto a variáveis aleatórias discretas quanto a variáveis aleatórias contínuas.
- A função de distribuição acumulada nos dá uma outra maneira de descrever como as probabilidades são associadas aos valores de uma variável aleatória.

### ▼ Definição

- A função de distribuição acumulada (f.d.a) de uma variável aleatória (discreta ou contínua)  $X$  é definida como

$$F(x) = \mathbb{P}(X \leq x) \quad \text{para todo } x$$

- **Propriedades:** Uma função de distribuição acumulada tem que satisfazer as seguintes condições:

$$(F1) \quad 0 \leq F(x) \leq 1$$

$$(F2) \quad F \text{ é não decrescente, isto é, } F(x) \leq F(y) \text{ sempre que } x \leq y, \quad \forall x, y \in \mathbb{R}.$$

$$(F3) \quad \text{Continuidade à direita. Se } x_n \downarrow x, \text{ então } F(x_n) \downarrow F(x).$$

$$(F4) \quad F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0 \quad e \quad F(\infty) = \lim_{x \rightarrow \infty} F(x) = 1.$$

### ▼ Demonstração das Propriedades

- **F1:** Como  $F(x)$  representa uma probabilidade segue-se que  $0 \leq F(x) \leq 1$ .
- **F2:** Note que  $[X \leq x] \cap [X \leq y]$  sempre que  $x \leq y$ . Logo as probabilidades satisfazem à desigualdade:

$$F(x) = P(X \leq x) \leq P(X \leq y) = F(y).$$

- **F3:** Seja  $x \in \mathbb{R}$  e considere uma sequência  $\{x_n, n \geq 1, n \in \mathbb{N}\}$  tal que  $x_n \downarrow x$ . Isto é, os  $x_n$ 's se aproximam de  $x$  pela direita ou, em outras palavras, por valores superiores a  $x$ . Então,  $[X \leq x_n] \downarrow [X \leq x]$  e, assim,  $P(X \leq x_n) \downarrow P(X \leq x)$ . Como o resultado vale para qualquer  $x$ , a propriedade está verificada.

- **F4**: Aplicamos a continuidade da probabilidade. Observe que para  $X_n \downarrow -\infty$ , os eventos  $[X \leq x_n] = \{w \in \Omega : X(w) \leq x_n\}$  têm como limite o conjunto vazio. Logo  $F(x_n) = P(X \leq x_n) \downarrow 0$ . De modo análogo, tomando  $X_n \uparrow \infty$ , os eventos  $[X \leq x_n] \uparrow \Omega$  e, portanto  $F(x_n) = P(X \leq x_n) \uparrow 1$ .

#### ▼ De Distribuição de Probabilidade para f.d.a

- Quando quisemos encontrar a **f.d.a** de uma **v.a.**, e o problema der a Distribuição de Probabilidade, podemos encontrar a **f.d.a** a partir da Distribuição de Probabilidade por meio da expressão:

$$F(x) = \sum_{i: x_i \leq x} P[X = x_i]$$

- O inverso também é possível:

$$P[X = x_i] = F(x_i) - \lim_{x \rightarrow -x_i} F(x)$$

#### ▼ Exemplos

##### ▼ Ex 1:

- Um grupo de 1000 crianças foi analisado para determinar a efetividade de uma vacina contra um tipo de alergia. As crianças recebiam uma dose de vacina e após um mês passavam por um novo teste. Caso ainda tivessem tido alguma reação alérgica, recebiam outra dose. Ao fim de 5 doses, foram consideradas imunizadas.
- Variável de interesse:  $X = \text{"número de doses"}$

Doses (X)	1	2	3	4	5
Freq.	245	288	256	145	66

- Uma criança é sorteada ao acaso, qual será a probabilidade dela ter recebido 2 doses?

$$P(X = 2) = \frac{288}{1000} = 0,288$$

Doses (X)	1	2	3	4	5
$p(x)$	0,245	0,288	0,256	0,145	0,066

- Qual a probabilidade da criança ter recebido até duas doses?

$$F(2) = P(X \leq 2) = P(X = 1) + P(X = 2) = 0,245 + 0,288 = 0,533$$

- Note que, tendo em vista que a variável só assume valores inteiros, esse valor fica inalterado no intervalo  $[2, 3)$ . Isto é ,  $F(2) = F(2,1) = F(2,45) = F(2,99)$ .
- Por essa razão escrevemos:


$$F(x) = P(X \leq x) = 0,533 \quad \text{para } 2 \leq x < 3$$

- Logo os valores completos da função de distribuição são os seguintes:

$$F(x) = \begin{cases} 0 & \text{se } x < 1; \\ 0,245 & \text{se } 1 \leq x < 2; \\ 0,533 & \text{se } 2 \leq x < 3; \\ 0,789 & \text{se } 3 \leq x < 4; \\ 0,934 & \text{se } 4 \leq x < 5; \\ 1 & \text{se } x \geq 5. \end{cases}$$



- A figura a seguir apresenta um diagrama dessa função:



## Esperança de v.a. Discretas ( $\mathbb{E}(X)$ )

### ▼ Definição

- **Definição:** Seja  $X$  uma variável aleatória discreta, com função de probabilidade  $p(x) = P(X = x)$ ,  $x = 1, 2, \dots, n, \dots$ . Então, a esperança (ou **valor esperado** ou **média**) de  $X$ , denotada por  $\mathbb{E}(X)$  é definida como:

$$\mathbb{E}(X) = \mu_x = \sum_{x=1}^n x \mathbb{P}(X = x) = \sum_{x=1}^n x p(x) \quad \forall x = 1, 2, 3, \dots, n$$

- A Esperança matemática também pode ser chamada de **valor médio**.
- Podemos usar o símbolo  $E$  para esperança quando houver mais de uma variável envolvida. Ou podemos usar o símbolo grego  $\mu$ , quando houver só uma variável.
- Colocando em palavras, o valor esperado de  $X$  é uma **média ponderada** dos possíveis valores que  $X$  pode receber, com cada valor sendo ponderado pela probabilidade de que  $X$  seja igual a esse valor. Por exemplo, se a função de probabilidade de  $X$  é dada por:

$$p(0) = \frac{1}{2} = p(1)$$

então

$$E[X] = 0 \left( \frac{1}{2} \right) + 1 \left( \frac{1}{2} \right) = \frac{1}{2}$$

Nesse caso acima é somente a média ordinária dos dois valores possíveis, 0 e 1, que  $X$  pode assumir. Por outro lado, se

$$p(0) = \frac{1}{3} \quad p(1) = \frac{2}{3}$$

então

$$E[X] = 0 \left( \frac{1}{3} \right) + 1 \left( \frac{2}{3} \right) = \frac{2}{3}$$

- Agora suponha que conheçamos uma variável aleatória discreta e sua função de probabilidade e que queiramos calcular o valor esperado de alguma função de  $X$ , digamos,  $g(X)$ . Como podemos fazer isso?
- Uma maneira é a seguinte: como  $g(X)$  é ela mesma uma variável aleatória discreta, ela tem uma função de probabilidade, que pode ser determinada a partir da função de probabilidade de  $X$ . Uma vez que tenhamos determinado a função de

probabilidade de  $g(X)$ , podemos calcular  $E[g(x)]$  usando a definição de valor esperado.

▼ **Exemplo:** Seja  $X$  uma variável aleatória que pode receber os valores  $-1, 0, 1$  com respectivas probabilidades:

$$P\{X = -1\} = 0,2 \quad P\{X = 0\} = 0,5 \quad P\{X = 1\} = 0,3$$

Calcule  $E[X^2]$

**Solução:** Seja  $Y = X^2$ . Então a função de probabilidade de  $Y$  é dada por

$$\begin{aligned} P\{Y = 1\} &= P\{X = -1\} + P\{X = 1\} = 0,5 \\ P\{Y = 0\} &= P\{X = 0\} = 0,5 \end{aligned}$$

Logo

$$E[X^2] = E[Y] = 1(0,5) + 0(0,5) = 0,5$$

Observe que

$$0,5 = E[X^2] \neq (E[X])^2 = 0,01$$

Embora o procedimento anterior sempre nos permita calcular o valor esperado de qualquer função de  $X$  a partir do conhecimento da função de probabilidade de  $X$ , há uma outra maneira de raciocinar sobre  $E[g(X)]$ : já que  $g(X)$  será igual a  $g(x)$  sempre que  $X$  for igual a  $x$ , parece razoável que  $E[g(X)]$  deva ser uma média ponderada dos valores  $g(x)$ , com  $g(x)$  sendo ponderado pela probabilidade de que  $X$  seja igual a  $x$ . Isto é, o resultado a seguir é bastante intuitivo:

$$E[g(X)] = \sum_i g(x_i)p(x_i)$$

- O exemplo acima feito com esse novo método:

$$\begin{aligned} E\{X^2\} &= (-1)^2(0,2) + 0^2(0,5) + 1^2(0,3) \\ &= 1(0,2 + 0,3) + 0(0,5) \\ &= 0,5 \end{aligned}$$

- **Obs:** O uso da denominação **média** para o valor esperado da variável tem origem histórica, mas também pode ser visto como uma referência a um resultado importante conhecido por **Lei dos Grandes Números**.
- **Momento:**
  - **Momento Central de Ordem  $k$ :** Para  $k = 1, 2, \dots$ , o momento de ordem  $k$  da variável  $X$  é definido por  $E(X^k)$ , desde que essa quantidade exista.  
Se  $E(X) = \mu < \infty$ , definimos o momento central de ordem  $k$  por  $E[(X - \mu)^k]$ , sempre que essa quantidade exista.
  - **Momento Absoluto de Ordem  $k$ :** De modo similar, o momento absoluto de ordem  $k$  da variável aleatória  $X$  é definido por  $E(|X|^k)$ .
  - A existência dos momentos está relacionada à discussão que fizemos sobre a existência da integral. Isto é, o valor infinito pode ocorrer, mas operações do tipo  $\infty - \infty$  são indeterminadas e levam à **inexistência** do momento.
  - É imediato notar que o momento de ordem  $1$  é o valor esperado, já definido anteriormente.

#### ▼ Propriedades

- Nas seguintes propriedades,  $X$  e  $Y$  é uma variável aleatória e  $a, b$  são constantes.

$$E(X + Y) = E(X) + E(Y)$$

$$E(X - Y) = E(X) - E(Y)$$

- $\mathbb{E}(a) = a$
- $\mathbb{E}(a + X) = a + \mathbb{E}(X)$
- $\mathbb{E}(bX) = b\mathbb{E}(X)$
- $\mathbb{E}(a + bX) = a + b\mathbb{E}(X)$
- Para  $r \geq 1$ , o  $r$ -ésimo momento de uma variável aleatória é definido por  $\mathbb{E}(X^r)$  (se existe).

## Variância de uma v.a. ( $Var(X)$ )

### ▼ Definição

- Dada uma variável aleatória  $X$  e sua função distribuição  $F$ , seria extremamente útil se pudéssemos resumir as propriedades essenciais de  $F$  em certas medidas convenientemente definidas.
- Uma dessas medidas seria  $E[X]$  o , valor esperado de  $X$ .
- Entretanto, embora  $E[A]$  forneça a média ponderada dos valores possíveis de  $X$ , ela não nos diz nada sobre a variação, ou dispersão, desses valores.
- **Por exemplo**, embora as v.a  $W$ ,  $Y$  e  $Z$  com funções discretas de probabilidade determinadas por

$$\begin{aligned} W &= 0 \quad \text{com probabilidade } 1 \\ Y &= \begin{cases} -1 & \text{com probabilidade } \frac{1}{2} \\ +1 & \text{com probabilidade } \frac{1}{2} \end{cases} \\ Z &= \begin{cases} -100 & \text{com probabilidade } \frac{1}{2} \\ +100 & \text{com probabilidade } \frac{1}{2} \end{cases} \end{aligned}$$

tenham todas a mesma esperança, que é igual a 0. Existe uma dispersão muito maior nos valores possíveis de  $Y$  do que naqueles de  $W$  (que é uma constante) e nos valores possíveis de  $Z$  do que naqueles de  $Y$ .

- Como esperamos que  $X$  assuma valores em torno de sua média  $E[X]$ , parece razoável que uma maneira de medir a possível variação de  $X$  seja ver, em média, quão distante  $X$  estaria de sua média.
- Uma possível maneira de se medir essa variação seria considerar a grandeza  $E[|X - \mu|]$ , onde  $\mu = E[X]$ . Entretanto, a manipulação dessa grandeza seria matematicamente inconveniente. Por esse motivo, uma grandeza mais tratável é usualmente considerada  $E[(X - \mu)^2]$  esta é a esperança do quadrado da diferença entre  $X$  e sua média. Temos assim a definição a seguir.
- **Definição:** Se  $X$  é uma variável aleatória com média  $\mu$ , então a variância de  $X$ , representada por  $Var(X)$ , é definida como:

$$Var(X) = \sigma^2 = E[(X - \mu)^2] = E\left[\left(X - E(X)\right)^2\right] = E(X^2) - E(X)^2$$

- Denominamos **Desvio-Padrão** de  $X$  a raiz quadrada positiva de  $Var(X)$ , e é denotada por  $DP(X)$ .

$$DP(X) = +\sqrt{Var(X)}$$

### ▼ Propriedades

- Nas seguintes propriedades,  $X$  é uma variável aleatória e  $a$ ,  $b$  são constantes.

$$Var(X) = E[(X - \mu)^2]$$

- $\text{Var}(a) = 0$
- $\text{Var}(a + X) = \text{Var}(X)$
- $\text{Var}(bX) = b^2 \text{Var}(X)$
- $\text{Var}(a + bX) = b^2 \text{Var}(X)$
- $\text{Var}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$

- **Demonstração** da quarta propriedade  $\text{Var}(a + bX) = b^2 \text{Var}(X)$

Sendo  $E(X) = \mu$ , por uma propriedade do valor esperado temos  $E(aX + b) = a + b E(X) = a + b\mu$ . Assim,

$$\begin{aligned} \text{Var}(a + bX) &= E\left[\left((a + bX) - (a + b\mu)\right)^2\right] = E\left[\left(a + bX - a - b\mu\right)^2\right] = E\left[\left(bX - b\mu\right)^2\right] = \\ &= b^2 E\left[\left(X - \mu\right)^2\right] = b^2 \text{Var}(X) \end{aligned}$$

- **Demonstração** da última propriedade  $\text{Var}(X) = E(X^2) - [E(X)]^2$ .

Para verificar, vamos desenvolver o quadrado do desvio e aplicar propriedades da esperança.

$$\begin{aligned} \text{Var}(X) &= E\left[(X - \mu)^2\right] = E\left[X^2 - 2X\mu + \mu^2\right] = E(X^2) - E(2X\mu) + E(\mu^2) = E(X^2) - 2\mu E(X) + \mu^2 = \\ &= E(X^2) - 2\mu^2 + \mu^2 = E(X^2) - \mu^2 = E(X^2) - E(X)^2 = \text{Var}(X) \end{aligned}$$

## Resumo das distribuições discretas

Distribuição	$P(X = x)$	Parâmetros	$E(X)$	$\text{Var}(X)$	f.g.p	f.g.m
Uniforme Discreta	$\frac{1}{N}, \quad x = 1, 2, \dots, N$	$N$	$\frac{N+1}{2}$	$\frac{N^2-1}{12}$	—	—
Bernoulli	$p^x(1-p)^{1-x}, \quad x = 0, 1$	$p$	$p$	$p(1-p)$	—	—
Binomial	$\binom{n}{x} p^x (1-p)^{n-x}, \quad x = 0, 1, \dots, n$	$n, p$	$np$	$np(1-p)$	$[pt + (1-p)]^n$	$(pe^t + 1 - p)^n$
Geométrica	$p(1-p)^{x-1}, \quad x = 1, 2, 3, \dots$	$p$	$\frac{1}{p}$	$\frac{1-p}{p^2}$	$\frac{pe^t}{1-(1-p)e^t}$	$\frac{pe^t}{1-e^t(1-p)}$
Binomial Negativa	$\binom{x-1}{r-1} p^r (1-p)^{x-r}, \quad x = r, (r+1), (r+2), \dots$	$r, p$	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$	—	$\left[\frac{pe^t}{1-e^t(1-p)}\right]^r$
Hipergeométrica	$\frac{\binom{r}{x} \binom{N-r}{n-x}}{\binom{N}{n}}, \quad x = 0, 1, 2, \dots$	$N, n, r$	$\frac{nr}{N}$	$\frac{nr}{N} \left(1 - \frac{r}{N}\right) \left(\frac{N-n}{N-1}\right)$	—	—
Poisson	$\frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots$	$\lambda$	$\lambda$	$\lambda$	$e^{\lambda(e^t-1)}$	$e^{\lambda(e^t-1)}$

## Distribuição Uniforme Discreta

### ▼ Definição

- Este é o caso mais simples de v.a. discreta, em que cada valor possível ocorre com a mesma probabilidade.
- Considere uma v.a  $X$  que toma um número finito de valores com a mesma probabilidade, ou seja,  $X \in \{1, 2, \dots, N\}$ .
- Dessa forma podemos notar que,

$$p(x) = P(X = x) = \frac{1}{N} \quad \text{para todo } x \in \{1, 2, \dots, N\}$$

- Uma v.a com essas propriedades é dita ter uma distribuição **uniforme discreta** com parâmetro  $N$ .
- **Notação:**  $X \sim U\{1, 2, \dots, N\}$ .
- Pode se mostrar que:



$$\mathbb{E}(X) = \frac{N+1}{2}$$

$$Var(X) = \frac{N^2-1}{2}$$

### ▼ Exemplo

▼ **Ex 1:** Lançamos um dado equilibrado e observamos a face que ocorreu. A v.a sera  $X$  = “resultado obtido no lançamento de um dado honesto”.

- Como todos os resultados de  $X$  são equiprováveis:

$x$	1	2	3	4	5	6
$p(x)$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$

- Podemos então usar a distribuição uniforme discreta, que sera:  $X \sim U\{1, 2, 3, 4, 5, 6\}$ .
- A **esperança** desse experimento vai ser:

$$E(X) = \frac{1}{6} \cdot (1 + 2 + 3 + 4 + 5 + 6) = \frac{21}{6} = 3,5$$

Poderíamos ter usado a formula de esperança para distribuição uniforme discreta:

$$E(X) = \frac{N+1}{2} = \frac{7}{2} = 3,5$$

- A **variância** desse experimento vai ser:

$$Var(X) = \frac{1}{6} \cdot \left[ (1 + 4 + 9 + 16 + 25 + 36) - \frac{1}{6} \cdot (21)^2 \right] = \frac{35}{2} = 17,5$$

Poderíamos ter usado a formula de variância para distribuição uniforme discreta:

$$E(X) = \frac{N^2-1}{2} = \frac{6^2-1}{12} = \frac{35}{2} = 17,5$$

## Modelo Bernoulli

### ▼ Definição

- Em muitas aplicações, cada observação de um experimento aleatório é binária: tem apenas dois resultados possíveis.
- Por exemplo, uma pessoa pode:

- aceitar ou recusar uma oferta de cartão de crédito de seu banco.
- ter ou não um plano de saúde.
- votar sim ou não em uma assembléia.

- Nesse caso, os resultados do experimento podem ser classificados como sucesso ou fracasso. Exemplos:

- Lançar uma moeda e verificar a ocorrência de cara ou coroa. Podemos considerar como sucesso, a obtenção de cara.
- Lançar um dado e verificar se o resultado é par ou ímpar. Podemos considerar como sucesso obter um número par.

- Esse tipo de experimento é denominado **ensaio de Bernoulli**. Ou seja se o experimento tem resposta dicotômica do tipo sucesso-fracasso, ele vai ser denominado ensaio de bernoulli.

## Distribuição Bernoulli

### ▼ Definição

- Experimentos que resultam numa v.a. de Bernoulli são chamados **ensaios de Bernoulli**.
- Para indicar a distribuição de Bernoulli com parâmetro  $p$  de uma v.a., usaremos a notação:

$$X \sim Ber(p)$$

O  $p$  é a probabilidade de ocorrer um evento o outro.

- Denotaremos com  $p$  a probabilidade de sucesso e  $1-p$  a probabilidade de fracasso:

$$\begin{aligned} P(X = 1) &= P(\text{sucesso}) = p \\ P(X = 0) &= P(\text{fracasso}) = 1 - p \end{aligned}$$


- Dizemos que  $X$  tem distribuição de Bernoulli com parâmetro  $p$  se sua função de probabilidade é dada por:

$$P(X = x) = p^x (1 - p)^{1-x} \quad \text{em que} \quad x = 0 \text{ ou } 1$$

- Logo por definição temos as formulas para esperança, variância e f.d.a:

- $\mathbb{E}(X) = 0 \times (1 - p) + 1 \times p = p$
- $\mathbb{E}(X^2) = 0^2 \times (1 - p) + 1^2 \times p = p$
- $\text{Var}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2 = p - p^2 = p(1 - p)$

- f.d.a.:  $F(x) = \begin{cases} 0, & x < 0 \\ 1 - p, & x \in [0, 1) \\ 1, & x \geq 1 \end{cases}$



### ▼ Exemplo

- ▼ **Ex 1:** Lançamos um dado e consideramos como sucesso, a obtenção da face 5. Supondo que o dado é honesto:

Logo o  $p$  vai ser igual a probabilidade de sair face 5:  $p = \frac{1}{6}$

$x$	0	1
$p(x)$	$\frac{5}{6}$	$\frac{1}{6}$

Vamos prova que a probabilidade se não sair a face 5:

$$P(X = 0) = p^0(1-p)^{1-0} = \left(\frac{1}{6}\right)^0 \left(\frac{5}{6}\right)^{1-0} = \frac{5}{6}$$

$$P(X = 1) = p^1(1-p)^{1-1} = \left(\frac{1}{6}\right)^1 \left(\frac{5}{6}\right)^{1-1} = \frac{1}{6}$$

Vamos calcular a  $E(X)$  e a  $Var(X)$ :

Pela definição  $E(X) = p$  e  $Var(X) = p(1-p)$ , então temos:

$$E(X) = \frac{1}{6}$$

$$Var(X) = \frac{1}{6} \left(1 - \frac{1}{6}\right) = \frac{1}{6} \cdot \frac{5}{6} = \frac{5}{36}$$

## Distribuição Binomial

### ▼ Definição

- A repetição de um ensaios de Bernoulli qualquer, onde cada repetição é **independente** da outra, dar origem a uma **variável aleatória Binomial**.
  - Definição:** Suponha que  $n$  ensaios de Bernoulli independentes, são realizados. Ou seja, em cada ensaio pode acontecer sucesso com probabilidade  $p$  ou fracasso com probabilidade  $1-p$ .
- Defina a v.a  $X$  como o **número de sucessos em  $n$  ensaios**, então  $X$  é dita ter distribuição binomial com parâmetros  $n$  e  $p$  e sua função de probabilidade é dada por:

$$p(x) = P(X = x) = \binom{n}{x} p^x (1-p)^{n-x} \quad \forall \quad x = \{0, 1, \dots, n\}$$

- Notação:**  $X \sim B(n, p)$ .
- Note que,  $Ber(p) \equiv B(1, p)$ .
- f.d.a  $P(X \leq x) = \sum_{i=0}^{\lfloor x \rfloor} \binom{n}{i} p^i (1-p)^{n-i}$
- Se  $X \sim B(n, p)$  então:
  - $E(X) = np$
  - $Var(X) = np(1-p)$
  - $E(X^k) = np E[(Y + 1)^{k-1}]$  sendo que  $Y \sim B(n-1, p)$ .
- Demonstração da  $E(X)$ ,  $E(X^2)$ ,  $E(X^k)$ ,  $Var(X)$ .**
  - ▼  $E(X)$ :

$$E(X) = \sum_{x=0}^n x \cdot p(x) = \sum_{x=1}^n x \cdot \binom{n}{x} p^x (1-p)^{n-x}$$

Note que, quando  $x = 0$  a equação vai ser igual a 0, logo o somatório começa no 1.

Note também:

$$x \cdot \binom{n}{x} = x \cdot \frac{n!}{x!(n-x)!} = x \cdot \frac{n(n-1)!}{x(x-1)!(n-x)!} = \frac{n(n-1)!}{(x-1)!(n-x)!} = n \binom{n-1}{x-1}$$

Logo:

$$\sum_{x=1}^n x \cdot \binom{n}{x} p^x (1-p)^{n-x} = \sum_{x=1}^n n \binom{n-1}{x-1} p^{x-1} p (1-p)^{(n-1)-(x-1)}$$

$$y = x - 1 \quad m = n - 1$$

$$np \sum_{y=0}^m \binom{m}{y} p^y (1-p)^{m-y} = np \cdot 1 = np$$

Note que essa última somatória da equação acima é a própria função de probabilidade da binomial que é igual a 1.

▼  $E(X^2)$ :

Sabemos que  $E(X) = np$  e para  $E(X^2)$  vem que

$$\begin{aligned} \mathbb{E}(X^2) &= \sum_{x=0}^n x^2 \binom{n}{x} p^x (1-p)^{n-x} \\ &\text{*Note que } x^2 = [x(x-1) + x] \\ &= \sum_{x=0}^n [x(x-1) + x] \binom{n}{x} p^x (1-p)^{n-x} \\ &= \left( \sum_{x=0}^n x(x-1) \binom{n}{x} p^x (1-p)^{n-x} \right) + \left( \sum_{x=0}^n x \binom{n}{x} p^x (1-p)^{n-x} \right) \\ &= \left( \sum_{x=0}^n x(x-1) \binom{n}{x} p^x (1-p)^{n-x} \right) + \mathbb{E}(X) \end{aligned}$$

\*Note que, o somatório deve começar no 2

$$\begin{aligned} &= \mathbb{E}(X) + \sum_{x=2}^n x(x-1) \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x} \\ &= \mathbb{E}(X) + \sum_{x=2}^n x(x-1) \frac{n(n-1)(n-2)!}{x(x-1)(x-2)!(n-x)!} p^x (1-p)^{n-x} \\ &= \mathbb{E}(X) + n(n-1) \sum_{x=2}^n \frac{(n-2)!}{(x-2)!(n-x)!} p^{x-2} \cdot p^2 (1-p)^{(n-2)-(x-2)} \\ &= \mathbb{E}(X) + n(n-1)p^2 \sum_{x=2}^n \binom{n-2}{x-2} p^{x-2} (1-p)^{(n-2)-(x-2)} \end{aligned}$$

\* $j = x - 2 \quad \forall j = 0, 1, 2, 3, \dots, n-2$

$$= \mathbb{E}(X) + n(n-1)p^2 \sum_{j=0}^{n-2} \binom{n-2}{j} p^j (1-p)^{(n-2)-j}$$

\*Note que o somatório é uma função de probabilidade logo ele é igual a 1

$$\begin{aligned} &= \mathbb{E}(X) + n(n-1)p^2 \cdot 1 \\ &= np + (n^2 - n)p^2 \\ &= np + n^2p^2 - np^2 \\ &= \mathbf{n^2p^2 + np(1-p)} \end{aligned}$$

▼  $E(X^k)$ :

$$E(X^k) = \sum_{x=0}^n x^k \cdot p(x) = \sum_{x=1}^n x^k \cdot \binom{n}{x} p^x (1-p)^{n-x}$$

Note que, quando  $x = 0$  a equação vai ser igual a 0, logo o somatório começa no 1.

Note também:

$$x^k \cdot \binom{n}{x} = x^k \cdot \frac{n!}{x!(n-x)!} = x^k \cdot \frac{n(n-1)!}{x(x-1)!(n-x)!} = x^{k-1} \frac{n(n-1)!}{(x-1)!(n-x)!} = x^{k-1} n \binom{n-1}{x-1}$$

Logo:

$$\begin{aligned}
\sum_{x=1}^n x^k \cdot \binom{n}{x} p^x (1-p)^{n-x} &= \sum_{x=1}^n x^{k-1} n \binom{n-1}{x-1} p^{x-1} p (1-p)^{(n-1)-(x-1)} = \\
&= np \sum_{x=1}^n x^{k-1} \binom{n-1}{x-1} p^{x-1} (1-p)^{(n-1)-(x-1)} \\
y = x-1 \quad m = n-1 \quad x = y+1 \quad \forall y = 0, 1, 2, 3, \dots, m \\
np \sum_{y=0}^m (y+1)^{k-1} \binom{m}{y} p^y (1-p)^{m-y} &= np \sum_{y=0}^m (y+1)^{k-1} p(x) \\
&= np \cdot E[(Y+1)^{k-1}]
\end{aligned}$$

Concluimos então:

$$E(X^k) = np \cdot E[(Y+1)^{k-1}] \quad Y \sim B(n-1; p)$$

Usando essa formula para calcular  $E(X^2)$ :

$$E(X^2) = np \cdot E(Y+1) = np \cdot [(n-1)p + 1]$$

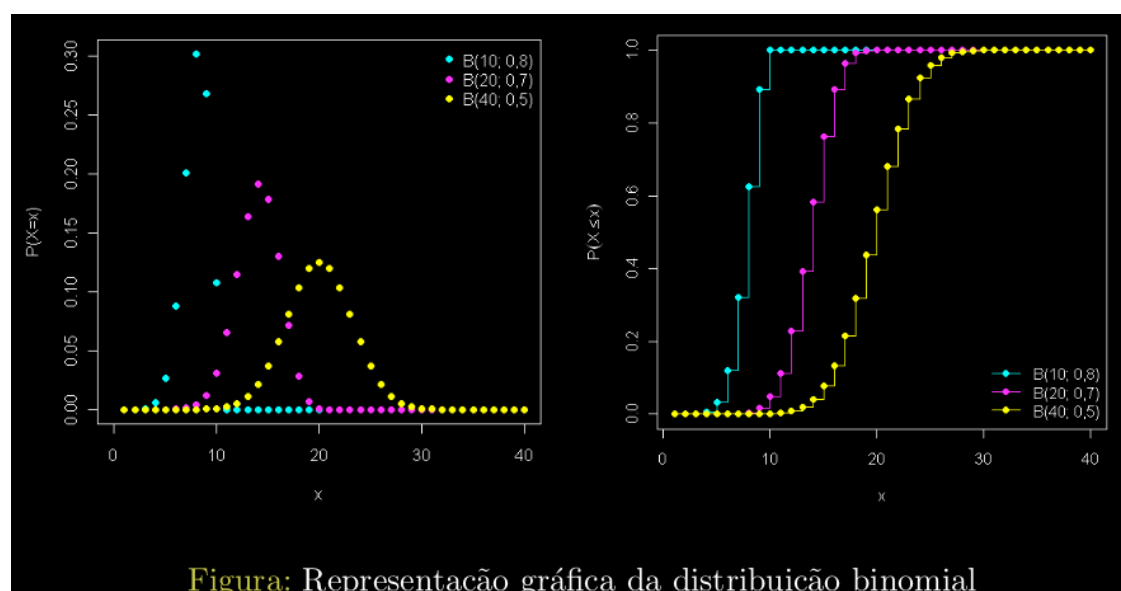
▼  $Var(X)$

$$\begin{aligned}
Var(X) &= E(X^2) - \mu^2 \\
&= n^2 p^2 + np(1-p) - (np)^2 \\
&= np(1-p)
\end{aligned}$$

• **Proposição:**

Se  $X \sim B(n, p)$  então

$$\mathbb{P}(X = x+1) = \frac{p}{1-p} \frac{n-x}{x+1} \mathbb{P}(X = x)$$



▼ **Exemplo**

▼ **Ex 1:** Sabe-se que a eficiência de uma vacina é de **80%**. Um grupo de **3** indivíduos é sorteado, dentre a **população vacinada**, e cada um é submetido a testes para averiguar se está imunizado. Nesse caso, consideramos como sucesso a imunização.

$$X_i = \begin{cases} 1, & \text{indivíduo } i \text{ está imunizado} \\ 0, & \text{caso contrário} \end{cases}$$

- Pelo enunciado, sabe-se que  $P(X_i = 1) = p = 0,8$ .
- Os três  $\{1, 2, 3\}$  indivíduos são independentes, cada um vai ter uma v.a  $\{X_1, X_2, X_3\}$ , que assumem valor **1** se o indivíduo está imunizado ou **0** caso contrário.

- A v.a  $X$  desse experimento vai ser igual ao número de indivíduos imunizados no grupo,  $X$  poderá assumir valores  $\{0, 1, 2, 3\}$ .
- Note que  $X = X_1 + X_2 + X_3$ .
- Logo o número de casos possíveis são:

evento	$\mathbb{P}(\text{evento})$	X
$X_1 = 0, X_2 = 0, X_3 = 0$	$(0,2)^3$	0
$X_1 = 1, X_2 = 0, X_3 = 0$	$0,8 \times (0,2)^2$	1
$X_1 = 0, X_2 = 1, X_3 = 0$	$0,8 \times (0,2)^2$	1
$X_1 = 0, X_2 = 0, X_3 = 1$	$0,8 \times (0,2)^2$	1
$X_1 = 1, X_2 = 1, X_3 = 0$	$(0,8)^2 \times 0,2$	2
$X_1 = 1, X_2 = 0, X_3 = 1$	$(0,8)^2 \times 0,2$	2
$X_1 = 0, X_2 = 1, X_3 = 1$	$(0,8)^2 \times 0,2$	2
$X_1 = 1, X_2 = 1, X_3 = 1$	$(0,8)^3$	3

- Assim, as probabilidades de cada valor possível de  $X$  são:

$x$	0	1	2	3
$p(x)$	$(0,2)^3$	$3 \times 0,8 \times (0,2)^2$	$3 \times (0,8)^2 \times 0,2$	$(0,8)^3$

- E o comportamento de  $X$  é completamente determinado pela função:

$$p(x) = P(X = x) = \binom{3}{x} (0,8)^x (1 - 0,8)^{n-x} \qquad \forall \qquad x = \{0, 1, 2, 3\}$$

### Distribuição Hipergeométrica

▼ Definição

$$p(x) = \mathbb{P}(X = x) = \frac{\binom{r}{x} \binom{N-r}{n-x}}{\binom{N}{n}}$$

- Este é um modelo para amostragem sem reposição de uma população com um número finito de elementos que podem ser classificados em duas categorias mutuamente excludentes.
- **Detalhes:**
  - $N$  objetos
  - $r$  possuem uma característica  $A$
  - $N-r$  possuem uma característica  $B$
  - Um grupo de  $n$  elementos é escolhido ao acaso, dentre os  $N$  possíveis, sem reposição.
- **Objetivo:** Calcular a probabilidade de que este grupo de  $n$  elementos contenha  $x$  elementos com a característica  $A$ .
- Seja  $X$  a v.a representando o número de elementos com a característica  $A$ , dentre os  $n$  elementos selecionados. Dizemos que  $X$  tem distribuição hipergeométrica e sua distribuição de probabilidade é dada por:

$$p(x) = \mathbb{P}(X = x) = \frac{\binom{r}{x} \binom{N-r}{n-x}}{\binom{N}{n}} \quad \forall$$

$$\max\{0, n - (N - r)\} \leq x \leq \min\{r, n\}.$$

- **Notação:**  $X \sim Hip(N, n, r)$
- Se  $X \sim Hip(N, n, r)$  então:
  - $\mathbb{E}(X) = n \frac{r}{N}$
  - $Var(X) = n \frac{r}{N} (1 - \frac{r}{N}) (\frac{N-n}{N-1})$

## Distribuição Geométrica

### ▼ Definição

- Consideremos uma sequência **ilimitada** de ensaios de Bernoulli, com probabilidade de sucesso  $p$  em cada ensaio.
- Realizamos os ensaios até que ocorra o primeiro sucesso.
- Seja  $X$  a variável aleatória que conta o número de ensaios até o primeiro sucesso.
- Então  $X$  segue Distribuição Geométrica com parâmetro  $0 < p < 1$  e a sua função de probabilidade é dada por:

$$\mathbb{P}(X = x) = p(1 - p)^{x-1} \text{ para todo } x = 1, 2, 3, \dots$$

$$F(x) = 1 - (1 - p)^x$$

- **Notação:**  $X \sim Geo(p)$ .
- **Propriedades:**
  - $E(X) = \frac{1}{p}$
  - $E(X^2) = \frac{2-p}{p^2}$
  - $Var(X) = \frac{1-p}{p^2}$
- **Demonstração:**
  - $E(X) = \frac{1}{p}$ .



Demonstração:  $E(X) = 1/p$ .

$$E(X) = \sum_{x=1}^{\infty} x p(x) = p \sum_{x=1}^{\infty} x (1-p)^{x-1} = p \sum_{x=1}^{\infty} x q^{x-1} =$$

\*  $f(q) = q^x$      $f'(q) = x q^{x-1}$     (Progressão Geométrica)

$$= p \sum_{x=1}^{\infty} x q^{x-1} = p \sum_{x=1}^{\infty} \frac{1}{1-q} q^x = p \frac{1}{1-q} \left[ \sum_{x=1}^{\infty} q^x \right] = p \frac{1}{1-q} [q + q^2 + q^3 + \dots]$$

$$= p \frac{1}{1-q} \left( \frac{q}{1-q} \right) = p \left[ \frac{q \cdot (1-q) - q \cdot (1-q)'}{(1-q)^2} \right] = p \left[ \frac{(1-q) + q}{(1-q)^2} \right] = \frac{p}{(1-q)^2} \frac{1}{p^2} = \frac{1}{p}$$

◦  $E(X^2) = \frac{2-p}{p^2}$

- O r-ésimo momento fatorial de uma v.a.  $X$  é definido por:

$$E[(X)_r] = E[X(X-1)(X-2)\dots(X-r+1)]$$

- Por exemplo, para  $r = 2$ , temos:

$$E[(X)_2] = E[X(X-1)] = \sum_{x=1}^{\infty} x(x-1)P(x)$$

- Note que:

$$E[X(X-1)] = E[X^2 - X] = E(X^2) - E(X)$$

- Logo:

$$E(X^2) = E[X(X-1)] + E(X)$$

- Agora, vamos encontrar o valor de  $E[X(X-1)]$ .

- Pela definição de esperança temos que:

$$E[X(X-1)] = \sum_{x=1}^{\infty} x(x-1)P(x)$$

- Pela definição de função de probabilidade da Distribuição Geométrica, temos que  $P(x) = p(1-p)^{x-1}$ , onde  $p$  é o parâmetro da Distribuição Geométrica.

$$\sum_{x=1}^{\infty} x(x-1)P(x) = \sum_{x=1}^{\infty} x(x-1)p(1-p)^{x-1} = p \sum_{x=1}^{\infty} x(x-1)(1-p)^{x-1}$$

- Agora vamos substituir  $(1-p)$  por  $q$  e vamos multiplicar e dividir por  $q$ :

$$p \sum_{x=1}^{\infty} x(x-1)(1-p)^{x-1} = p \sum_{x=1}^{\infty} x(x-1)q^{x-1} \frac{q}{q} = pq \sum_{x=1}^{\infty} x(x-1)q^{x-2}$$

- Note que a derivada segunda de  $q^x$  é igual a:



$$\frac{d^2}{dq^2}(q^x) = \frac{d}{dq}(xq^{x-1}) = x(x-1)q^{x-2}$$

- Logo temos:

$$pq \sum_{x=1}^{\infty} x(x-1)q^{x-2} = pq \sum_{x=1}^{\infty} \frac{d^2}{dq^2} q^x = pq \frac{d^2}{dq^2} \sum_{x=1}^{\infty} q^x = pq \frac{d^2}{dq^2} [q^2 + q^3 + q^4 + \dots]$$

- Note que o somatório é uma PG, logo a soma dos termos de uma PG infinita é dada pela fórmula  $\frac{a_1}{1-r}$ , nesse caso temos então  $\left(\frac{q^2}{1-q}\right)$ . Essa fórmula só é válida para progressões geométricas decrescentes, com  $0 < q < 1$ :

$$pq \frac{d^2}{dq^2} [q^2 + q^3 + q^4 + \dots] = pq \frac{d^2}{dq^2} \left( \frac{q^2}{1-q} \right)$$

- Resolvendo a derivada, temos:

$$pq \frac{d^2}{dq^2} \left( \frac{q^2}{1-q} \right) = pq \frac{2}{(1-q)^3} = \frac{2pq}{(1-q)^3}$$

- Substituindo o  $q$  pelo valor original  $q = 1 - p$ :

$$\frac{2pq}{(1-q)^3} = \frac{2p(1-p)}{(1-(1-p))^3} = \frac{2p(1-p)}{(1-1+p)^3} = \frac{2p(1-p)}{p^3} = \frac{2(1-p)}{p^2}$$

- Pronto agora vamos voltar para a fórmula do  $\mathbb{E}(X^2)$ :

$$\mathbb{E}(X^2) = \mathbb{E}[X(X-1)] + \mathbb{E}(X) = \frac{2(1-p)}{p^2} + \frac{1}{p} = \frac{2(1-p) + p}{p^2} = \frac{2 - 2p + p}{p^2} = \frac{2-p}{p^2}$$

- $Var(X) = \frac{1-p}{p^2}$ .

*Demonstração:*

$$Var(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2 = \frac{2-p}{p^2} - \left(\frac{1}{p}\right)^2 = \frac{2-p}{p^2} - \frac{1}{p^2} = \frac{1-p}{p^2}$$

- **Proposição:**

Seja  $X \sim \text{Geo}(p)$ . Para quaisquer números inteiros positivos  $s$  e  $t$ , vale

$$\mathbb{P}(X \geq s+t | X \geq s) = \mathbb{P}(X \geq t).$$

- Essa propriedade é conhecida como **Falta de Memória Geométrica**.
- Ela indica a maneira como a variável incorpora a informação anterior.
- Em termos ilustrativos, podemos considerar que a variável “lembra” do presente, mais “esqueceu” do que ocorreu no passado.

Por exemplo, se  $X$  representasse a espera em dias para a ocorrência de um certo evento, a probabilidade condicional acima representaria a probabilidade de espera de pelo menos  $m + n$  dias, sabendo que o evento não ocorreu antes de  $m$  dias. A propriedade da falta de memória estabelece que essa probabilidade é a mesma de esperar pelo menos  $n$  dias.

Para verificar a propriedade, observe que

$$P(X \geq m + n | X \geq m) = \frac{P([X \geq m + n] \cap [X \geq m])}{P(X \geq m)} = \frac{P(X \geq m + n)}{P(X \geq m)}.$$

A função de probabilidade de  $X$  é dada por  $P(X = x) = p(1 - p)^x$ . Então,

$$P(X \geq m + n | X \geq m) = \frac{(1 - p)^{m+n}}{(1 - p)^m} = (1 - p)^n = P(X \geq n).$$

- Pode ainda demonstrar que o modelo Geométrico é o único modelo discreto com a propriedade da falta de memória.
- Uma generalização do modelo Geométrico é o Modelo Binomial Negativo.

## Distribuição Binomial Negativa (Pascal)

### ▼ Definição

- Esta distribuição pode ser considerada como uma generalização da distribuição geométrica.
- Considere uma sequência ilimitada de ensaios de Benoulli, e seja  $X$  a v.a. que conta o número de ensaios até a ocorrência de  $r$  sucessos.
- Nessas condições  $X$  é dita ter distribuição **binomial negativa**.
- E sua função de probabilidade é dada por:

$$\mathbb{P}(x) = \mathbb{P}(X = x) = \binom{x-1}{r-1} p^r (1-p)^{x-r} \quad \forall x = r, r+1, r+2, \dots$$

- **Notação:**  $X \sim BN(r, p)$
- Logo temos:
  - $E(X) = \frac{r}{p}$
  - $Var(X) = \frac{r(1-p)}{p^2}$
- **Obs:** A distribuição geométrica equivale a:

$$Geo(p) \equiv BN(1, p)$$

- A distribuição binomial negativa pode, também, ser definida em termos da v.a  $Y$  que conta o número de fracassos antes do  $r$ -ésimo sucesso. Esta formulação é equivalente a definição anterior, uma vez que,  $Y = X - r$ .

$$P(y) = P(Y = y) = \binom{r+y-1}{y} p^r (1-p)^y, \quad \forall y = 0, 1, \dots$$

- Podemos ver que:

$$\sum_{x=r}^{\infty} P(X = x) = \sum_{x=r}^{\infty} \binom{x-1}{r-1} p^r (1-p)^{x-r} = 1 \quad (1)$$

Pela própria definição da Função de Probabilidade fica provado que a equação (1) é igual a 1.

### ▼ Demonstração: Mais podemos mostra que a equação (1) é igual a 1:

- Para podemos fazer essa demonstração, vamos precisar primeiro mostrar alguns teoremas.

- **Teorema Binomial:**  $(1+x)^r = 1 + rx + \binom{r}{2}x^2 + \binom{r}{3}x^3 + \dots$ 
  - Para provamos essa igualdade, vamos considera  $f(x) = (1+x)^r$ , e vamos usar a serie de Taylor, mais especificamente a serie de Mac-laurim.
  - Então temos:

$$\begin{aligned}(1+x)^r &= f(0) + f'(0)x + f''(0)\frac{x^2}{2!} + f'''(0)\frac{x^3}{3!} + \dots + f^{(r)}(0)\frac{x^r}{r!} \\ &= 1 + rx + \frac{r(r-1)}{2!}x^2 + \frac{r(r-1)(r-2)}{3!}x^3 + \dots\end{aligned}$$

note que:

$$\binom{n}{p} = \frac{n!}{p!(n-p)!} = \frac{n(n-1)(n-2)\dots(n-p+1)(n-p)!}{p!(n-p)!} = \frac{n(n-1)(n-2)\dots(n-p+1)}{p!}$$

então, usando essa afirmação na equação anterior temos:

$$\begin{aligned}(1+x)^r &= 1 + rx + \frac{r(r-1)}{2!}x^2 + \frac{r(r-1)(r-2)}{3!}x^3 + \dots \\ &= 1 + rx + \binom{r}{2}x^2 + \binom{r}{3}x^3 + \dots\end{aligned}$$

logo fica provado o teorema binomial.

- Note que essa serie pode ser representado por um somatório:

$$(1+x)^r = 1 + rx + \binom{r}{2}x^2 + \binom{r}{3}x^3 + \dots = \sum_{k=0}^{\infty} \binom{r}{k}x^k$$

- Agora vamos demostrar que:
- **Demonstração:**  $(1-x)^{-r} = \sum_{k=0}^{\infty} \binom{r+k-1}{k}x^k$ 
  - Sabemos que pelo teorema binomial podemos escrever o  $(1-x)^{-r}$  como:

$$(1-x)^{-r} = \sum_{k=0}^{\infty} \binom{-r}{k}(-x)^k$$

para facilitar as contas vamos retira o sinal negativo do  $x$ :

$$(1-x)^{-r} = \sum_{k=0}^{\infty} \binom{-r}{k}(-x)^k = \sum_{k=0}^{\infty} (-1)^k \binom{-r}{k}x^k \quad (2)$$

- Agora vamos **demostrar** que  $\binom{-r}{k}(-1)^k = \binom{r+k-1}{k}$
- Temos que:

$$\begin{aligned}\binom{-r}{k}(-1)^k &= \frac{-r(-r-1)(-r-2)\dots(-r-k+1)(-r-k)!}{k!(-r-k)!}(-1)^k \\ &= \frac{-r(-r-1)(-r-2)\dots(-r-k+1)}{k!}(-1)^k\end{aligned}$$

podemos colocar o menos em evidência:

$$\begin{aligned}\binom{-r}{k}(-1)^k &= \frac{-r(-r-1)(-r-2)\cdots(-r-k+1)}{k!}(-1)^k \\ &= (-1)^k \frac{r(r+1)(r+2)\cdots(r+k-1)}{k!}(-1)^k\end{aligned}$$

note que  $(-1)^k \cdot (-1)^k = 1$  para todo  $k$  ímpar ou par.

$$\binom{-r}{k}(-1)^k = \frac{r(r+1)(r+2)\cdots(r+k-1)}{k!} \cdot 1$$

agora vamos reescrever a equação acima de trás para frente:

$$\begin{aligned}\binom{-r}{k}(-1)^k &= \frac{r(r+1)(r+2)\cdots(r+k-1)}{k!} \cdot 1 \\ &= \frac{(r+k-1)(r+k-2)\cdots(r+2)(r+1)r}{k!}\end{aligned}$$

veja que o termo depois do  $r$  é o  $(r-1)!$  que foi cancelado com o fatorial do denominador:

$$\begin{aligned}\binom{-r}{k}(-1)^k &= \frac{(r+k-1)(r+k-2)\cdots(r+2)(r+1)r}{k!} \\ &= \frac{(r+k-1)(r+k-2)\cdots(r+2)(r+1)r(r-1)!}{k!(r-1)!} \\ &= \frac{(r+k-1)!}{k!(r-1)!} \\ &= \binom{r+k-1}{k}\end{aligned}$$

- Agora podemos voltar pra a equação (2), lembrando ela era:

$$(1-x)^{-r} = \sum_{k=0}^{\infty} (-1)^k \binom{-r}{k} x^k$$

temos então a equação (3):

$$(1-x)^{-r} = \sum_{k=0}^{\infty} (-1)^k \binom{-r}{k} x^k = \sum_{k=0}^{\infty} \binom{r+k-1}{k} x^k \quad (3)$$

- Pronto, agora podemos provar a equação (1), lembrando ela era:

$$\sum_{x=r}^{\infty} \binom{x-1}{r-1} p^r (1-p)^{x-r} = 1$$

- Se  $X \sim BN(r, p)$ , então

$$\mathbb{P}(X = x) = \binom{x-1}{r-1} p^r (1-p)^{x-r} \quad \forall \ x = r, r+1, r+2, \dots$$

- Então:

$$\begin{aligned}\sum_{x=r}^{\infty} \binom{x-1}{r-1} p^r (1-p)^{x-r} &= p^r \sum_{x=r}^{\infty} \binom{x-1}{r-1} (1-p)^{x-r} \\ &= p^r \sum_{x=r}^{\infty} \binom{x-1}{r-1} q^{x-r} \quad q = (1-p)\end{aligned}$$

- Vamos substituir o  $x - r$  por  $y$ , e por consequência o  $x = y + r$ :

$$p^r \sum_{x=r}^{\infty} \binom{x-1}{r-1} q^{x-r} = p^r \sum_{x=r}^{\infty} \binom{r+y-1}{r-1} q^y$$

- Essa combinação pode ser reescrita como:

$$\binom{r+y-1}{r-1} = \frac{(r+y-1)!}{(r-1)! [r+y-1-(r-1)]!} = \frac{(r+y-1)!}{(r-1)! y!} = \binom{r+y-1}{y}$$

- Logo temos:

$$p^r \sum_{x=r}^{\infty} \binom{r+y-1}{r-1} q^y = p^r \sum_{x=r}^{\infty} \binom{r+y-1}{y} q^y$$

- Pela equação (3) sabemos que:

$$p^r \sum_{x=r}^{\infty} \binom{r+y-1}{y} q^y = p^r (1-q)^{-r} = \frac{p^r}{(1-q)^r} = \frac{p^r}{(1-(1-p))^r} = \frac{p^r}{p^r} = 1$$

- **Curiosidade:**

- Pascal ou binomial negativa?
- Jain (1991) (página 492) considera Pascal e binomial negativa **distintas**. A binomial negativa é definida como sendo o número de falhas antes de ocorrerem  $r$  sucessos.
- Grinstead e Snell (1997), página 186, chamam a Pascal de binomial negativa.
- Para Meyer(1983), página 204, a distribuição de Pascal pode ser chamada de binomial negativa.

## Distribuição Poisson

### ▼ Definição

- É um modelo discreto que expressa a probabilidade de um dado número de eventos ocorrer em um intervalo contínuo (que pode ser tempo ou espaço) se esses eventos ocorrem com uma taxa média conhecida e independentemente do tempo decorrido desde o último evento.
- Seja  $X$  a v.a aleatória que conta a ocorrência de um determinado evento em um intervalo contínuo. Então  $X$  tem distribuição de Poisson com parâmetro  $\lambda$  e sua distribuição de probabilidade é dada por:

$$\mathbb{P}(X = x) = \frac{e^{-\lambda} \lambda^x}{x!} \quad \forall \quad x = 0, 1, 2, \dots$$

em que,  $e$  é a base do logaritmo natural ( $e = 2,71828\dots$ )

- $\lambda$  é um número real, igual ao número esperado de ocorrências num dado intervalo de tempo.
- **Propriedades importantes:**
  - $e^\lambda = \sum_{x=0}^{\infty} \frac{\lambda^x}{x!}$ , demostramos por serie de Mac-Lourim:

$$e^\lambda = 1 + \lambda + \frac{\lambda^2}{2!} + \frac{\lambda^3}{3!} + \dots = \sum_{x=0}^{\infty} \frac{\lambda^x}{x!}$$

- $e^{-\lambda} = 1 - \lambda + \frac{\lambda^2}{2!} - \frac{\lambda^3}{3!} + \dots$
- $\sum_{x=0}^{\infty} \frac{e^{-\lambda} \lambda^x}{x!} = e^{-\lambda} \cdot \sum_{x=0}^{\infty} \frac{\lambda^x}{x!} = e^{-\lambda} \cdot e^\lambda = 1$
- $\lim_{x \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^{-x} = 1$

$$\lim_{x \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^{-x} = \lim_{x \rightarrow \infty} \frac{1}{\left(1 - \frac{\lambda}{n}\right)^x} = \lim_{x \rightarrow \infty} \left[ \frac{1}{\left(1 - \frac{\lambda}{n}\right)} \cdot \frac{1}{\left(1 - \frac{\lambda}{n}\right)} \cdots \frac{1}{\left(1 - \frac{\lambda}{n}\right)} \right] = \lim_{x \rightarrow \infty} \left[ \frac{1}{1-0} \cdot \frac{1}{1-0} \cdots \frac{1}{1-0} \right] = 1$$

- $\lim_{x \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^n = e^{-\lambda}$
- $\lim_{x \rightarrow \infty} \frac{(n)_x}{n^x} = 1$

$$\lim_{x \rightarrow \infty} \frac{(n)_x}{n^x} = \lim_{x \rightarrow \infty} \frac{n}{n} \cdot \frac{(n-1)}{n} \cdot \frac{(n-2)}{n} \cdots \frac{(n-x+1)}{n} = \lim_{x \rightarrow \infty} 1 \cdot \left(1 - \frac{1}{n}\right) \left(1 - \frac{2}{n}\right) \cdots \left(1 - \frac{x-1}{n}\right) = (1-0)(1-0) \cdots (1-0) = 1$$

- **Demonstração para  $\mathbb{P}(X = x)$ :**

A variável aleatória de Poisson encontra uma tremenda faixa de aplicações em diversas áreas porque pode ser usada como uma aproximação para a variável aleatória binomial com parâmetros  $(n, p)$  no caso particular de  $n$  **grande** e  $p$  suficientemente **pequeno** para que  $np$  tenha **tamanho moderado**. Para ver isto, suponha que  $X$  seja uma variável aleatória **binomial** com parâmetros  $(n, p)$ , e suponha que  $\lambda = np$ . Então:

$$\begin{aligned} \mathbb{P}(X = x) &= \binom{n}{x} p^x (1-p)^{n-x} \\ &= \frac{n!}{x!(n-x)!} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x} \quad * p = \frac{\lambda}{n} \\ &= \frac{n(n-1)(n-2) \cdots (n-x+1)}{x!} \cdot \frac{\lambda^x}{n^x} \cdot \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-x} \\ &= \frac{(n)_x}{n^x} \cdot \frac{\lambda^x}{x!} \cdot \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-x} \\ &= 1 \cdot \frac{\lambda^x}{x!} \cdot e^{-\lambda} \cdot 1 \\ &= \frac{e^{-\lambda} \lambda^x}{x!} \end{aligned}$$

- Notação:  $X \sim P(\lambda)$ .
  - $E(X) = \lambda$
  - $E(X^2) = \lambda(\lambda + 1)$
  - $Var(X) = \lambda$
- **Demonstração da  $E(X)$ ,  $E(X^2)$ ,  $Var(X)$** 
  - ▼  $E(X) = \lambda$

$$\begin{aligned}
\mathbb{E}(X) &= \sum_{x=0}^{\infty} x \cdot \frac{e^{-\lambda} \cdot \lambda^x}{x!} \\
&= \sum_{x=0}^{\infty} x \cdot \frac{e^{-\lambda} \cdot \lambda^{x-1} \cdot \lambda}{x(x-1)!} \\
&= \lambda e^{-\lambda} \sum_{x=0}^{\infty} \frac{\lambda^{x-1}}{(x-1)!} \\
&= \lambda e^{-\lambda} \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} \\
&= \lambda e^{-\lambda} \cdot e^{\lambda} \\
&= \lambda
\end{aligned}$$

▼  $E(X^2) = \lambda(\lambda + 1)$

$$\begin{aligned}
\mathbb{E}(X^2) &= \sum_{x=0}^{\infty} x^2 \cdot \frac{e^{-\lambda} \cdot \lambda^x}{x!} \\
&= \sum_{x=0}^{\infty} x^2 \cdot \frac{e^{-\lambda} \cdot \lambda^{x-1} \cdot \lambda}{x(x-1)!} \\
&= \lambda \sum_{x=0}^{\infty} \frac{x \cdot e^{-\lambda} \lambda^{x-1}}{(x-1)!} \\
&= \lambda \sum_{j=0}^{\infty} \frac{(j+1)e^{-\lambda} \lambda^j}{j!} \quad * j = x - 1 \\
&= \lambda \left[ \sum_{j=0}^{\infty} \frac{j e^{-\lambda} \lambda^j}{j!} \right] + \left[ \sum_{j=0}^{\infty} \frac{e^{-\lambda} \lambda^j}{j!} \right] \\
&= \lambda(\lambda + 1)
\end{aligned}$$

▼  $Var(X) = \lambda$

$$Var(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2 = \lambda(\lambda + 1) - \lambda^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$$

▼ **Exemplo:** Seja  $X$  uma v.a.d., tal que  $p(x) = \frac{e^{-\lambda} \lambda^x}{x!(1-e^{-\lambda})}$  para  $x = 1, 2, 3, \dots$ .

i. Mostre que  $p(x)$  é de fato uma função de probabilidade.

$$\sum_{x=1}^{\infty} \frac{e^{-\lambda} \cdot \lambda^x}{x!(1-e^{-\lambda})} = \frac{e^{-\lambda}}{(1-e^{-\lambda})} \sum_{x=1}^{\infty} \frac{\lambda^x}{x!}$$

Note que  $\sum_{x=1}^{\infty} \frac{\lambda^x}{x!}$  é igual a  $\sum_{x=0}^{\infty} \frac{\lambda^x}{x!}$  menos o valor da equação quando o  $x = 0$  Logo o somatório  $\sum_{x=1}^{\infty} \frac{\lambda^x}{x!}$  vai ser igual a:

$$\sum_{x=1}^{\infty} \frac{\lambda^x}{x!} = \left( \sum_{x=0}^{\infty} \frac{\lambda^x}{x!} \right) - \frac{\lambda^0}{0!} = e^{\lambda} - 1$$

Então,

$$\frac{e^{-\lambda}}{(1-e^{-\lambda})} \sum_{x=1}^{\infty} \frac{\lambda^x}{x!} = \frac{e^{-\lambda}}{(1-e^{-\lambda})} \cdot (e^{\lambda} - 1) = \frac{e^0 - e^{-\lambda}}{(1-e^{-\lambda})} = \frac{1 - e^{-\lambda}}{1 - e^{-\lambda}} = 1$$

ii. Determine  $\mathbb{E}(X)$  e  $Var(X)$ .

Para a  $\mathbb{E}(X)$  temos:

$$\begin{aligned}
\mathbb{E}(X) &= \sum_{x=1}^{\infty} x \cdot \frac{e^{-\lambda} \cdot \lambda^x}{x!(1 - e^{-\lambda})} \\
&= \frac{e^{-\lambda}}{(1 - e^{-\lambda})} \sum_{x=1}^{\infty} x \cdot \frac{\lambda^{(x-1)} \lambda}{x(x-1)!} \\
&= \frac{\lambda e^{-\lambda}}{(1 - e^{-\lambda})} \sum_{x=1}^{\infty} \frac{\lambda^{(x-1)}}{(x-1)!} \\
&= \frac{\lambda e^{-\lambda}}{(1 - e^{-\lambda})} \sum_{y=0}^{\infty} \frac{\lambda^y}{y!} \quad * y = x - 1 \quad \forall y = 0, 1, 2, 3, \dots \\
&= \frac{\lambda e^{-\lambda}}{(1 - e^{-\lambda})} \cdot e^{\lambda} \\
&= \frac{\lambda}{1 - e^{-\lambda}}
\end{aligned}$$

Para  $\mathbb{E}(X^2)$  temos:

$$\begin{aligned}
\mathbb{E}[X(X-1)] &= \sum_{x=1}^{\infty} x(x-1) \cdot \frac{e^{-\lambda} \cdot \lambda^x}{x!(1 - e^{-\lambda})} \\
&= \frac{e^{-\lambda}}{(1 - e^{-\lambda})} \sum_{x=1}^{\infty} x(x-1) \cdot \frac{\lambda^{(x-2)} \lambda^2}{x(x-1)(x-2)!} \\
&= \frac{\lambda^2 e^{-\lambda}}{(1 - e^{-\lambda})} \sum_{x=1}^{\infty} \frac{\lambda^{(x-2)}}{(x-2)!} \\
&= \frac{\lambda^2 e^{-\lambda}}{(1 - e^{-\lambda})} \sum_{y=0}^{\infty} \frac{\lambda^y}{y!} \quad * y = x - 2 \quad \forall y = 0, 1, 2, 3, \dots \\
&= \frac{\lambda^2 e^{-\lambda}}{(1 - e^{-\lambda})} \cdot e^{\lambda} \\
&= \frac{\lambda^2}{1 - e^{-\lambda}}
\end{aligned}$$

Note que,

$$\mathbb{E}[X(X-1)] = \mathbb{E}(X^2) - \mathbb{E}(X)$$

Logo,

$$\mathbb{E}(X^2) = \mathbb{E}[X(X-1)] + \mathbb{E}(X) = \frac{\lambda^2}{1 - e^{-\lambda}} + \frac{\lambda}{1 - e^{-\lambda}} = \frac{\lambda^2 + \lambda}{(1 - e^{-\lambda})}$$

Para  $Var(X)$  temos:

$$\begin{aligned}
Var(X) &= \mathbb{E}(X^2) - \mathbb{E}(X)^2 \\
&= \frac{\lambda^2 + \lambda}{(1 - e^{-\lambda})} - \left( \frac{\lambda}{1 - e^{-\lambda}} \right)^2 \\
&= \frac{\lambda^2 + \lambda}{(1 - e^{-\lambda})} - \frac{\lambda^2}{(1 - e^{-\lambda})^2}
\end{aligned}$$





Função Geradora de Probabilidade

▼ Definição

- Em teoria de probabilidade, a **Função Geradora de Probabilidade (f.g.p.)** de uma variável aleatória discreta é uma representação em **série de potências** da função de probabilidade da uma variável aleatória discreta que assume somente valores não-negativos.
- Se  $X$  for uma variável aleatória discreta assumindo valores nos inteiros não negativos  $\{0, 1, \dots\}$ , então a função geradora de probabilidade de  $X$  é definida como

$$G(t) = \mathbb{E}(t^x) = \sum_x t^x \mathbb{P}(X = x)$$

Demonstração:

$$\begin{aligned} G(t) &= P_0 t^0 + P_1 t^1 + P_2 t^2 + P_3 t^3 + \dots + P_n t^n \\ &= P_0 + P_1 t + P_2 t^2 + P_3 t^3 + \dots + P_n t^n \\ &= \sum_x t^x \cdot p(x) \\ &= \mathbb{E}(t^x) \end{aligned}$$

- Ex:** Seja  $X$  uma v.a.d. com a seguinte distribuição de probabilidade.

x	0	1	2	...	n
$p(x)$	$P_0$	$P_1$	$P_2$	...	$P_n$

Podemos associar as probabilidades aos coeficientes de um polinômio da seguinte forma:

$$G(t) = P_0 + P_1 t + P_2 t^2 + P_3 t^3 + \dots + P_n t^n$$

Note que para  $t = 1$  temos:

$$G(1) = P_0 + P_1 + P_2 + P_3 + \dots + P_n = 1$$

▼ Propriedades:

- $G(1) = P_0 + P_1 + P_2 + P_3 + \dots + P_n = 1$
- $G(t)' = \sum_x x t^{x-1} p(x)$

$$G(t) = P_0 + P_1 t + P_2 t^2 + P_3 t^3 + P_4 t^4 + \dots + P_n t^n$$

$$G(t)' = P_1 + 2P_2 t + 3P_3 t^2 + 4P_4 t^3 + \dots + nP_n t^{n-1}$$

- $G(t)'' = \sum_x x(x-1) t^{x-2} p(x)$

$$G(t)'' = 2P_2 + 6P_3 t + 12P_4 t^2 + \dots + n(n-1)P_n t^{n-2}$$

- $\mathbb{E}(X) = G(1)'$

$$\begin{aligned} G(t) &= P_0 + P_1 t + P_2 t^2 + P_3 t^3 + \dots + P_n t^n \\ G(t)' &= P_1 + 2P_2 t + 3P_3 t^2 + 4P_4 t^3 \dots + nP_n t^{n-1} \\ G(1)' &= P_1 + 2P_2 + 3P_3 + 4P_4 \dots + nP_n = \sum_{x=1}^n x p(x) = \mathbb{E}(X) \end{aligned}$$

- $\mathbb{E}[X(X-1)] = G(1)''$

$$\begin{aligned} G(1)'' &= 2P_2 + 6P_3 \cdot 1 + 12P_4 \cdot 1^2 + \dots + n(n-1)P_n \cdot 1^{n-2} \\ &= 2P_2 + 6P_3 + 12P_4 + \dots + n(n-1)P_n \\ &= \sum_{x=2} x(x-1) \cdot p(x) \\ &= \mathbb{E}[X(X-1)] \end{aligned}$$

- $Var(X) = G(1)'' + G(1)' - [G(1)']^2$

$$\begin{aligned} G(1)'' &= \mathbb{E}[X(X-1)] = \mathbb{E}(X^2) - \mathbb{E}(X) \\ \mathbb{E}(X^2) &= G(1)'' + G(1)' = \mathbb{E}[X(X-1)] + \mathbb{E}(X) = \mathbb{E}(X^2) - \mathbb{E}(X) + \mathbb{E}(X) = \mathbb{E}(X^2) \\ Var(X) &= G(1)'' + G(1)' - [G(1)']^2 \end{aligned}$$

- $G(0) = P_0 = p(0)$
- $G(0)' = P_1 = p(1)$
- $G(0)'' = 2P_2$
- $G(0)^{(3)} = 6P_3$
- $G(0)^{(k)} = k!P_k$
- $\frac{G(0)''}{2} = P_2 = p(2)$
- $\frac{G(0)'''}{6} = P_3 = p(3)$
- $p(x) = P_x = \frac{G(0)^{(x)}}{x!}$

▼ Binomial

$$G(t) = \mathbb{E}(t^x) = \sum_{x=0}^n t^x p(x) = \sum_{x=0}^n t^x \binom{n}{x} p^x (1-p)^{n-x} = \sum_{x=0}^n \binom{n}{x} (tp)^x (1-p)^{n-x}$$

Note que no último somatório temos o termo geral de um binômio de newton, usando a formula  $(a+b)^n = \sum_{p=0}^n \binom{n}{p} a^{n-p} b^p$ , temos:

$$\sum_{x=0}^n \binom{n}{x} (tp)^x (1-p)^{n-x} = [pt + (1-p)]^n$$

Logo,

$$G(t) = [pt + (1-p)]^n$$

- Vamos ver agora, que as propriedades citadas anteriormente sobre função geradora, são verdadeira:

- $G(t) = [pt + (1-p)]^n$
- $G(1) = 1$

$$G(1) = [p \cdot 1 + (1-p)]^n = [p + 1 - p]^n = 1^n = 1$$

- $G(t)' = np[pt + (1-p)]^{n-1}$

$$G(t)' = \left( [pt + (1-p)]^n \right)' = n[pt + (1-p)]^{n-1} \cdot (pt + 1 - p)' = n[pt + (1-p)]^{n-1} \cdot (p \cdot 1 + 0 - 0) = n[pt + (1-p)]^{n-1} \cdot p = np[pt + (1-p)]^{n-1}$$

- $G(1)' = \mathbb{E}(X) = np$

$$G(1)' = np[p \cdot 1 + (1-p)]^{n-1} = np[p + 1 - p]^{n-1} = np \cdot 1^{n-1} = np$$

- $G(t)'' = n(n-1)p^2[pt + (1-p)]^{n-2}$
- $G(1)'' = n(n-1)p^2 = \mathbb{E}[X(X-1)]$

$$G(1)'' = n(n-1)p^2[p \cdot 1 + (1-p)]^{n-2} = n(n-1)p^2[p + 1 - p]^{n-2} = n(n-1)p^2(1)^{n-2} = n(n-1)p^2$$

- $Var(X) = G(1)'' + G(1)' - [G(1)']^2$

$$Var(X) = G(1)'' + G(1)' - [G(1)']^2 = n(n-1)p^2 + np - (np)^2 = n^2p^2 - np^2 + np - n^2p^2 = -np^2 + np = np(1-p)$$

- $p(0) = G(0) = (1-p)^n$
- $p(1) = G(0)' = np(1-p)^n$
- $p(2) = \frac{G(0)''}{2} = \frac{n(n-1)}{2} \cdot p^2(1-p)^{n-2}$
- $p(x) = \frac{G(0)^{(x)}}{x!}$

#### ▼ Geométrica

$$\begin{aligned} G(t) &= \mathbb{E}(t^x) \\ &= \sum_{x=1}^n t^x p(x) \\ &= \sum_{x=1}^n t^x p(1-p)^{x-1} \\ &= p \sum_{x=1}^n t^x (1-p)^{x-1} \cdot \frac{(1-p)}{(1-p)} \\ &= \frac{p}{(1-p)} \sum_{x=1}^n t^x (1-p)^x \\ &= \frac{p}{(1-p)} \sum_{x=1}^n [t(1-p)]^x \\ &= \frac{p}{(1-p)} \left[ t(1-p) + (t(1-p))^2 + (t(1-p))^3 + \dots \right] \quad * \text{ PG } q = t(1-p) \\ &= \frac{p}{(1-p)} \cdot \frac{t(1-p)}{1 - t(1-p)} \\ &= \frac{pt}{1 - t(1-p)} \end{aligned}$$

- Note que esse resultado só é valido para  $t(1-p) < 1$ , logo o  $t < \frac{1}{1-p}$ .

#### ▼ Propriedades:

- $G(t) = \frac{pt}{1-t(1-p)}$
- $G(1) = 1$

$$G(1) = \frac{p}{1 - (1-p)} = \frac{p}{1 - 1 + p} = \frac{p}{p} = 1$$

- $G(t)' = \frac{p \cdot (1-t+pt) - pt \cdot (-1+p)}{(1-t+pt)^2} = \frac{p}{(1-t+pt)^2}$

$$G(t)' = \left( \frac{pt}{1-t(1-p)} \right)' = \left( \frac{pt}{1-t+pt} \right)' = \frac{p \cdot (1-t+pt) - pt \cdot (-1+p)}{(1-t+pt)^2} = \frac{p}{(1-t+pt)^2}$$

- $G(1)' = \mathbb{E}(X) = \frac{1}{p}$

$$G(1)' = \frac{p \cdot (1-1+p \cdot 1) - p \cdot 1 \cdot (-1+p)}{(1-1+p \cdot 1)^2} = \frac{p^2 + p - p^2}{p^2} = \frac{p}{p^2} = \frac{1}{p}$$

- $G(t)'' = \frac{2p-2p^2}{(1-t+pt)^3}$

$$G(t)'' = \left( \frac{p}{(1-t+pt)^2} \right)' = \frac{-p \cdot 2(1-t+pt)(-1+p)}{(1-t+pt)^4} = -\frac{2p(-1+p)}{(1-t+pt)^3} = -\frac{-2p+2p^2}{(1-t+pt)^3} = \frac{2p-2p^2}{(1-t+pt)^3}$$

- $G(1)'' = \mathbb{E}[X(X-1)] = \frac{2-2p}{p^2}$

$$G(1)'' = \frac{2p-2p^2}{(1-1+p \cdot 1)^3} = \frac{2p-2p^2}{p^3} = \frac{p(2-2p)}{p^3} = \frac{2-2p}{p^2}$$

- $Var(X) = G(1)'' + G(1)' - [G(1)']^2 = \frac{1-p}{p^2}$

$$Var(X) = G(1)'' + G(1)' - [G(1)']^2 = \frac{2-2p}{p^2} + \frac{1}{p} - \left[ \frac{1}{p} \right]^2 = \frac{2-2p}{p^2} + \frac{1}{p} - \frac{1}{p^2} = \frac{2-p}{p^2} - \frac{1}{p^2} = \frac{1-p}{p^2}$$

#### ▼ Poisson

$$\begin{aligned} G(t) &= \mathbb{E}(t^x) \\ &= \sum_{x=1}^n t^x p(x) \\ &= \sum_{x=1}^n t^x \frac{e^{-\lambda} \cdot \lambda^x}{x!} \\ &= e^{-\lambda} \sum_{x=1}^n \frac{(t \cdot \lambda)^x}{x!} \\ &= e^{-\lambda} \cdot e^{t\lambda} \\ &= e^{-\lambda+t\lambda} \\ &= e^{\lambda(t-1)} \end{aligned}$$

#### ▼ Propriedades:

- $G(t) = e^{\lambda(t-1)}$
- $G(1) = 1$

$$G(1) = e^{\lambda(1-1)} = e^0 = 1$$

- $G(t)' = \lambda e^{\lambda t - \lambda}$

$$G(t)' = \left( e^{\lambda(t-1)} \right)' = \left( e^{\lambda t - \lambda} \right)' = e^{\lambda t - \lambda} \cdot (\lambda t - \lambda)' = e^{\lambda t - \lambda} \cdot (\lambda - 0) = \lambda e^{\lambda t - \lambda}$$

- $G(1)' = \mathbb{E}(X) = \lambda$

$$G(1)' = \lambda e^{\lambda - \lambda} = \lambda e^0 = \lambda$$

- $G(t)'' = \lambda^2 e^{\lambda t - \lambda}$

$$G(t)' = \left( \lambda e^{\lambda t - \lambda} \right)' = \lambda e^{\lambda t - \lambda} \cdot (\lambda t - \lambda)' = \lambda e^{\lambda t - \lambda} \cdot \lambda = \lambda^2 e^{\lambda t - \lambda}$$

- $G(1)'' = \mathbb{E}[X(X-1)] = \lambda^2$

$$G(1)'' = \lambda^2 e^{\lambda - \lambda} = \lambda^2 e^0 = \lambda^2$$

- $Var(X) = G(1)'' + G(1)' - [G(1)']^2 = \lambda$

$$Var(X) = G(1)'' + G(1)' - [G(1)']^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$$

#### ▼ Exemplos

▼ **Ex1:** Considere  $X$  uma v.a.d assumindo valores não-negativos com a seguinte f.g.p:

$$G_X(t) = A \left( \frac{10+8t^2}{2-t} \right) \quad \forall t \in (-2, 2)$$

a. Determine o valor de  $A$ .

Sabemos que  $G_X(1) = 1$ , logo

$$\begin{aligned} G_X(1) &= A \left( \frac{10+8 \cdot 1^2}{2-1} \right) = A(10+8) = 1 \\ A(10+8) &= 1 \iff A = \frac{1}{18} \end{aligned}$$

b. Determine o valor esperado de  $X$ .

Sabemos que o  $\mathbb{E}(X) = G(1)'$ , logo

$$G_X(t)' = \left[ \frac{1}{18} \cdot \left( \frac{10 + 8t^2}{2 - t} \right) \right]' = \frac{1}{18} \cdot \left( \frac{10 + 8t^2}{2 - t} \right)' = \frac{1}{18} \cdot \left( \frac{16t \cdot (2 - t) - (10 + 8t^2) \cdot (-1)}{(2 - t)^2} \right) = \frac{1}{18} \cdot \left( \frac{32t - 8t^2 + 10}{(2 - t)^2} \right)$$

Para  $G_X(1)'$  temos:

$$G_X(1)' = \frac{1}{18} \cdot \left( \frac{32 - 8 + 10}{(2 - 1)^2} \right) = \frac{1}{18} \cdot \frac{34}{1} = \frac{34}{18} = \frac{17}{9}$$

$$\mathbb{E}(X) = \frac{17}{9}$$

▼ **Ex2:** Se se  $X \sim \text{Poisson}(\lambda)$  prove com f.g.p que:

$$\mathbb{E}(X_{(r)}) = \mathbb{E}[X(X - 1)(X - 2) \cdots (X - r + 1)] = \lambda^r$$

Vamos começar provando que  $\mathbb{E}(X_{(r)}) = \mathbb{E}[X(X - 1)(X - 2) \cdots (X - r + 1)]$

$$\begin{aligned} G'(t) &= \sum_x x t^{x-1} p(x) \\ G'(1) &= \sum_x x p(x) = \mathbb{E}(X) \\ G''(t) &= \sum_x x(x - 1) t^{x-2} p(x) \\ G''(1) &= \sum_x x(x - 1) p(x) = \mathbb{E}[X(X - 1)] = \mathbb{E}(X_{(2)}) \\ G'''(t) &= \sum_x x(x - 1)(x - 2) t^{x-3} p(x) \\ G'''(1) &= \sum_x x(x - 1)(x - 2) p(x) = \mathbb{E}[X(X - 1)(X - 2)] = \mathbb{E}(X_{(3)}) \\ G^{(r)}(t) &= \sum_x x(x - 1)(x - 2) \cdots (x - r + 1) t^{x-r} p(x) \\ G^{(r)}(1) &= \sum_x x(x - 1)(x - 2) \cdots (x - r + 1) p(x) = \mathbb{E}[X(X - 1)(X - 2) \cdots (x - r + 1)] = \mathbb{E}(X_{(r)}) \end{aligned}$$

Agora vamos prova que  $\mathbb{E}(X_{(r)}) = \lambda^r$ , note que:

$$\begin{aligned} G(t) = \mathbb{E}(t^X) &= \sum_{x=0}^{\infty} t^x \frac{e^{-\lambda} \cdot \lambda^x}{x!} = e^{-\lambda} \cdot \sum_{x=0}^{\infty} \frac{(t\lambda)^x}{x!} = e^{-\lambda} \cdot e^{t\lambda} = e^{\lambda(t-1)} \\ G'(t) &= \lambda e^{\lambda(t-1)} \Rightarrow G'(1) = \lambda \\ G''(t) &= \lambda^2 e^{\lambda(t-1)} \Rightarrow G''(1) = \lambda^2 \\ G'''(t) &= \lambda^3 e^{\lambda(t-1)} \Rightarrow G'''(1) = \lambda^3 \\ &\vdots \\ G^{(r)}(t) &= \lambda^r e^{\lambda(t-1)} \Rightarrow G^{(r)}(1) = \lambda^r \end{aligned}$$

Note que  $\mathbb{E}(X_{(r)}) = G^{(r)}(1) = \lambda^r$ .

## Função Geradora de Momento

### ▼ Definição

- Em teoria de probabilidade a função geradora de momento (**f.g.m**) de uma v.a. discreta ou continua fornece uma especificação alternativa para a distribuição de probabilidade.
- Definição:** Seja  $X$  uma v.a.d ou v.a.c. A função geradora de momentos de  $X$  é definida por:

$$M_X(t) = \mathbb{E}(e^{tX})$$

deste que a esperança seja finita para  $t \in \mathbb{R}$  em algum inteiro  $-t_0 < t < t_0$  com  $t_0 > 0$ .

**Obs:** Se essa condição não for satisfeita, dizemos que a f.g.m não existe.

**Obs:** No caso de  $X$  ser uma v.a.d, então:

$$M_X(t) = \mathbb{E}(e^{tX}) = \sum_x e^{tx} p(x)$$

Note que:

$$\begin{aligned} e^x &= 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \cdots \\ e^{tx} &= 1 + tx + \frac{(tx)^2}{2!} + \frac{(tx)^3}{3!} + \cdots \end{aligned}$$

Logo,

$$M_x(t) = \mathbb{E}(e^{tX}) = 1 + t\mathbb{E}(X) + \frac{t^2\mathbb{E}(X^2)}{2!} + \frac{t^3\mathbb{E}(X^3)}{3!} + \cdots$$

- Chamamos  $M(t)$  de função geradora de momentos porque todos os momentos de  $X$  podem ser obtidos com o cálculo sucessivo da derivada de  $M(t)$  e então com sua avaliação em  $t = 0$ .
- A função geradora de momentos determina de forma unívoca a distribuição da variável aleatória, ou seja, existe uma única distribuição com função geradora  $m(t)$ . Por outro lado, se duas variáveis aleatórias possuem uma mesma função geradora então possuem a mesma distribuição.

▼ **Propriedades:**

- $M_X(0) = \mathbb{E}(e^{0X}) = \mathbb{E}(1) = 1$
- ▼  $M'(t) = \mathbb{E}(X) + t\mathbb{E}(X^2) + \frac{t^2\mathbb{E}(X^3)}{2} + \frac{t^3\mathbb{E}(X^4)}{6} + \dots$

$$\begin{aligned} M'(t) &= \mathbb{E}(e^{tX})' = \left( 1 + t\mathbb{E}(x) + \frac{t^2\mathbb{E}(X^2)}{2!} + \frac{t^3\mathbb{E}(X^3)}{3!} + \frac{t^4\mathbb{E}(X^4)}{4!} + \dots \right)' \\ &= 0 + \mathbb{E}(x) + \frac{2t\mathbb{E}(X^2)}{2!} + \frac{3t^2\mathbb{E}(X^3)}{3!} + \frac{4t^3\mathbb{E}(X^4)}{4!} + \dots \\ &= \mathbb{E}(x) + t\mathbb{E}(X^2) + \frac{t^2\mathbb{E}(X^3)}{2} + \frac{t^3\mathbb{E}(X^4)}{6} + \dots \end{aligned}$$

- $M'(0) = \mathbb{E}(X)$
- ▼  $M''(t) = \mathbb{E}(X^2) + t\mathbb{E}(X^3) + \frac{t^2\mathbb{E}(X^4)}{2} + \frac{t^3\mathbb{E}(X^5)}{6} + \dots$

$$\begin{aligned} M''(t) &= \mathbb{E}(e^{tX})'' = \left( \mathbb{E}(x) + t\mathbb{E}(X^2) + \frac{t^2\mathbb{E}(X^3)}{2} + \frac{t^3\mathbb{E}(X^4)}{6} + \frac{t^4\mathbb{E}(X^5)}{24} + \dots \right)' \\ &= 0 + \mathbb{E}(X^2) + \frac{2t\mathbb{E}(X^3)}{2} + \frac{3t^2\mathbb{E}(X^4)}{6} + \frac{4t^3\mathbb{E}(X^5)}{24} + \dots \\ &= \mathbb{E}(X^2) + t\mathbb{E}(X^3) + \frac{t^2\mathbb{E}(X^4)}{2} + \frac{t^3\mathbb{E}(X^5)}{6} + \dots \end{aligned}$$

- $M''(0) = \mathbb{E}(X^2)$
- $M^{(r)}(t) = \mathbb{E}(X^r) + t\mathbb{E}(X^{r+1}) + \sum_{n=2}^{\infty} \frac{t^n \cdot \mathbb{E}(X^{r+n})}{n!}$
- $M^{(r)}(0) = \mathbb{E}(X^r)$
- $M''(0) - [M'(0)]^2 = \text{Var}(X)$

▼ **Função Característica**

- Existe uma outra função, estreitamente relacionada com a f.g.m, a qual é frequentemente empregada em seu lugar.
- Ela é denominada função característica e é denota por:

$$\phi_X(t) = \mathbb{E}(e^{itX}) = \mathbb{E}[\cos(tX)] + i \mathbb{E}[\sin(tX)]$$

para  $t \in \mathbb{R}$  e  $i = \sqrt{-1}$  (unidade imaginária).

- As funções característica tem a vantagem de sempre existir. Entretanto, teremos o inconveniente de trabalhar com uma função de valores complexos.

▼ **Binomial**

$$\begin{aligned} M_X(t) &= \mathbb{E}(e^{tX}) = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x} \\ &= \sum_{x=0}^n \binom{n}{x} (e^t p)^x (1-p)^{n-x} \\ &= (pe^t + 1 - p)^n \end{aligned}$$

- A última igualdade decorre de uma aplicação direta do teorema binomial.

▼ **Propriedades:**

- $M'(t) = n(pe^t + 1 - p)^{n-1} pe^t$
- $M'(0) = \mathbb{E}(X) = np$

$$\mathbb{E}(X) = M'(0) = n(pe^0 + 1 - p)^{n-1} pe^0 = n(p + 1 - p)^{n-1} p = np(1)^{n-1} = np$$

- $M''(t) = npe^t \cdot (pe^t + 1 - p)^{n-1} + (n^2 p^2 e^{2t} - np^2 e^{2t}) \cdot (pe^t + 1 - p)^{n-2}$

$$\begin{aligned} M''(t) &= \left( n(pe^t + 1 - p)^{n-1} pe^t \right)' \\ &= \left( npe^t (pe^t + 1 - p)^{n-1} \right)' \\ &= \left( (npe^t)' \cdot (pe^t + 1 - p)^{n-1} \right) + \left( npe^t \cdot \left( (pe^t + 1 - p)^{n-1} \right)' \right) \\ &= \left( npe^t \cdot (pe^t + 1 - p)^{n-1} \right) + \left( npe^t \cdot (n-1)(pe^t + 1 - p)^{n-2} \cdot pe^t \right) \\ &= \left( npe^t \cdot (pe^t + 1 - p)^{n-1} \right) + \left( (n^2 p^2 e^{2t} - np^2 e^{2t}) \cdot (pe^t + 1 - p)^{n-2} \right) \\ &= npe^t \cdot (pe^t + 1 - p)^{n-1} + (n^2 p^2 e^{2t} - np^2 e^{2t}) \cdot (pe^t + 1 - p)^{n-2} \end{aligned}$$

- $M''(0) = \mathbb{E}(X^2) = n^2 p^2 + np(1 - p)$

$$\begin{aligned} M''(0) &= npe^0 \cdot (pe^0 + 1 - p)^{n-1} + (n^2 p^2 e^{2 \cdot 0} - np^2 e^{2 \cdot 0}) \cdot (pe^0 + 1 - p)^{n-2} \\ &= np \cdot (p + 1 - p)^{n-1} + (n^2 p^2 - np^2) \cdot (p + 1 - p)^{n-2} \\ &= np \cdot 1^{n-1} + (n^2 p^2 - np^2) \cdot 1^{n-2} \\ &= np + n^2 p^2 - np^2 \\ &= n^2 p^2 + np(1 - p) \end{aligned}$$

- $\text{Var}(X) = M(0)'' - [M(0)']^2$

$$\text{Var}(X) = M(0)'' - [M(0)']^2 = n^2 p^2 + np(1 - p) - (np)^2 = np(1 - p)$$

▼ **Geométrica**

$$\begin{aligned}
M_X(t) &= \mathbb{E}(e^{tX}) = \sum_{x=1}^{\infty} e^{tx} p(1-p)^{x-1} \\
&= \sum_{x=1}^{\infty} e^{tx} p(1-p)^{x-1} \cdot \frac{(1-p)}{1-p} \\
&= \frac{p}{1-p} \sum_{x=1}^{\infty} \left[ e^t(1-p) \right]^x \\
&= \frac{p}{q} \sum_{x=1}^{\infty} (e^t q)^x \\
&= \frac{p}{q} \left[ e^t q + (e^t q)^2 + (e^t q)^3 + \dots \right] \\
&= \frac{p}{q} \cdot \frac{e^t q}{1 - e^t q} \\
&= \frac{pe^t}{1 - e^t q}
\end{aligned}$$

Note que essa resultado só é válido para  $\forall e^t q < 1$ , logo  $e^t < \frac{1}{q} \implies t < \ln\left(\frac{1}{q}\right)$ .

▼ **Propriedades:**

- $M(0) = 1$

$$M(0) = \frac{p \cdot e^0}{1 - e^0 q} = \frac{p}{1 - q} = \frac{p}{1 - (1 - p)} = \frac{p}{p} = 1$$

- $M'(t) = \frac{pe^t}{(1 - e^t q)^2}$

$$M(t)' = \frac{pe^t \cdot (1 - e^t q) - pe^t \cdot e^t q}{(1 - e^t q)^2} = \frac{pe^t - p q e^{2t} - p q e^{2t}}{(1 - e^t q)^2} = \frac{pe^t}{(1 - e^t q)^2}$$

- $M'(0) = \mathbb{E}(X) = \frac{1}{p}$

$$\mathbb{E}(X) = M'(0) = \frac{pe^0}{(1 - e^0 q)^2} = \frac{p}{(1 - q)^2} = \frac{p}{(1 - (1 - p))^2} = \frac{p}{p^2} = \frac{1}{p}$$

- ▼  $M''(t) = \frac{pe^t(1 + qe^t)}{(1 - e^t q)^3}$

$$\begin{aligned}
M(t)'' &= \left( \frac{pe^t}{(1 - e^t q)^2} \right)' \\
&= \frac{pe^t(1 - e^t q)^2 - pe^t 2(1 - e^t q)(-e^t q)}{(1 - e^t q)^4} \\
&= \frac{pe^t(1 - e^t q)^2 + 2p q e^{2t}(1 - e^t q)}{(1 - e^t q)^4} \\
&= \frac{(1 - e^t q) \left[ pe^t(1 - e^t q) + 2p q e^{2t} \right]}{(1 - e^t q)^4} \\
&= \frac{pe^t(1 - e^t q) + 2p q e^{2t}}{(1 - e^t q)^3} \\
&= \frac{pe^t - p q e^{2t} + 2p q e^{2t}}{(1 - e^t q)^3} \\
&= \frac{pe^t + p q e^{2t}}{(1 - e^t q)^3} \\
&= \frac{pe^t(1 + qe^t)}{(1 - e^t q)^3}
\end{aligned}$$

- ▼  $M''(0) = \mathbb{E}(X^2) = \frac{2-p}{p^2}$

$$\begin{aligned}
M''(0) &= \frac{pe^0(1 + qe^0)}{(1 - e^0 q)^3} \\
&= \frac{p(1 + q)}{(1 - q)^3} \\
&= \frac{p(1 + (1 - p))}{(1 - (1 - p))^3} \\
&= \frac{p(2 - p)}{p^3} \\
&= \frac{2 - p}{p^2}
\end{aligned}$$

- $Var(X) = M(0)'' - \left[ M(0)' \right]^2$

$$Var(X) = M(0)'' - \left[ M(0)' \right]^2 = \frac{2 - p}{p^2} - \frac{1}{p^2} = \frac{1 - p}{p^2}$$

▼ **Poisson**

$$\begin{aligned}
M_X(t) &= \mathbb{E}(e^{tX}) = \sum_{x=0}^{\infty} e^{tx} \frac{e^{-\lambda} \cdot \lambda^x}{x!} \\
&= e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} \\
&= e^{-\lambda} \cdot e^{\lambda e^t} \\
&= e^{-\lambda + \lambda e^t} \\
&= e^{\lambda(e^t - 1)}
\end{aligned}$$

▼ Exemplos

▼ **Ex1:** Se  $X \sim B(n, p)$  determine a distribuição de  $Y = n - X$  utilizando a f.g.m de  $X$ .

$$M_Y(t) = \mathbb{E}(e^{tY}) = \mathbb{E}(e^{t(n-X)}) = \mathbb{E}(e^{tn} \cdot e^{-tX}) = e^{tn} \cdot \mathbb{E}(e^{-tX}) = e^{tn} \cdot M_X(-t)$$

Como v.a.d  $X$  tem distribuição binomial com parâmetros  $n$  e  $p$ , e sabemos que a f.g.m de uma distribuição binomial é  $(pe^t + 1 - p)^n$ , logo temos:

$$\begin{aligned}
e^{tn} \cdot M_X(-t) &= e^{tn} \cdot (pe^{-t} + 1 - p)^n = (e^t)^n \cdot (pe^{-t} + 1 - p)^n = \left[ (e^t) \cdot (pe^{-t} + 1 - p) \right]^n = \left[ (e^t) \cdot (pe^{-t} + 1 - p) \right]^n \\
&= \left[ p + e^t(1 - p) \right]^n
\end{aligned}$$

Então  $Y$  tem distribuição binomial com parâmetros  $n$  e  $(1 - p)$ .

$$Y \sim B(n; 1 - p)$$

▼ **Ex2:** Se  $X$  tem f.g.m  $M_X(t)$ , determine a f.g.m de  $Y = aX + b$ .

$$M_Y(t) = \mathbb{E}(e^{tY}) = \mathbb{E}(e^{t(aX+b)}) = \mathbb{E}(e^{taX} \cdot e^{tb}) = e^{bt} \cdot \mathbb{E}(e^{atX}) = e^{bt} \cdot M_X(at)$$

▼ **Ex3:** Seja  $X$  uma v.a. tal que  $p(x) = \frac{e^{-\lambda} \lambda^x}{x!(1-e^{-\lambda})} \quad \forall x = 1, 2, 3 \dots$

a. Determine o f.g.m de  $X$ .

$$\begin{aligned}
M_X(t) &= \mathbb{E}(e^{tX}) = \sum_{x=1}^{\infty} e^{tx} \frac{e^{-\lambda} \cdot \lambda^x}{x!(1-e^{-\lambda})} \\
&= \frac{e^{-\lambda}}{(1-e^{-\lambda})} \sum_{x=1}^{\infty} \frac{(\lambda e^t)^x}{x!} + 1 - 1 \\
&= \frac{e^{-\lambda}}{(1-e^{-\lambda})} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} - 1 \\
&= \frac{e^{-\lambda}}{(1-e^{-\lambda})} \cdot (e^{\lambda e^t} - 1) \\
&= \frac{e^{\lambda e^t} - e^{-\lambda}}{(1-e^{-\lambda})} \\
&= \frac{e^{\lambda e^t} - \frac{1}{e^\lambda}}{1 - \frac{1}{e^\lambda}} \\
&= \frac{\frac{e^{\lambda e^t} - 1}{e^\lambda}}{\frac{e^\lambda - 1}{e^\lambda}} \\
&= \frac{e^{\lambda e^t} - 1}{e^\lambda - 1}
\end{aligned}$$

b. Determine o valor esperado de  $X$  usando a f.g.m.

$$\begin{aligned}
M_X(t)' &= \left( \frac{e^{\lambda e^t} - 1}{e^\lambda - 1} \right)' \\
&= \frac{1}{e^\lambda - 1} (e^{\lambda e^t} - 1)' \\
&= \frac{1}{e^\lambda - 1} (e^{\lambda e^t} \cdot \lambda e^t) \\
&= \frac{e^{\lambda e^t} \cdot \lambda e^t}{e^\lambda - 1}
\end{aligned}$$

Logo,

$$\mathbb{E}(X) = M_X(0)' = \frac{e^{\lambda e^0} \cdot \lambda e^0}{e^\lambda - 1} = \frac{e^\lambda \cdot \lambda}{e^\lambda - 1}$$